Modélisation de la probabilité de défaut en risque de crédit

Rapport : méthodologie, résultats et analyse

Parcours MAFi – Mathématiques, Algorithmique, Finance et Informatique

11 octobre 2026

Résumé

Ce rapport présente la construction d'un modèle de probabilité de défaut (PD) à partir d'un portefeuille de prêts. Chaque étape est réalisée par du code Python versionné ; les tableaux et figures de ce document sont produits par ce code (dossier `resultats/`) et inclus sans retranscription manuelle. Il couvre l'ensemble du sujet : qualité des données et valeurs aberrantes (1.1), transformation des variables (1.2), sélection des variables (1.3), régression logistique et sélection pas à pas (1.4), robustesse, probabilité de défaut et XGBoost (1.5).

Table des matières

1 Introduction **3**
- 1.1 Contexte et objectif . . . 3
- 1.2 Données . . . 3
- 1.3 Démarche générale . . . 3
- 1.4 Reproductibilité et traçabilité . . . 3

2 Analyse de la qualité des données **4**
- 2.1 Variables disponibles et variable cible (question 1) . . . 4
- 2.2 Identifiants et variables à faible variabilité (question 2) . . . 7
- 2.3 Valeurs manquantes (question 3) . . . 8
- 2.4 Contrôles de cohérence (question 4) . . . 9
  - 2.4.1 Doublons et libellés . . . 11
  - 2.4.2 Traitements appliqués et synthèse . . . 11
- 2.5 Découpage apprentissage / test . . . 12

3 Valeurs aberrantes **13**
- 3.1 Méthodes de détection . . . 13
- 3.2 Distributions . . . 14
- 3.3 Résultats des deux méthodes . . . 16
- 3.4 Valeurs extrêmes : erreurs ou observations réelles ? . . . 18
- 3.5 Stratégies de traitement (question 6) . . . 19
- 3.6 Traitement retenu . . . 19

4 Variables dérivées **21**
- 4.1 Définitions et interprétation économique . . . 21
- 4.2 Construction . . . 22
- 4.3 Effet observé sur le défaut . . . 24
- 4.4 Redondances . . . 25

5 Discrétisation, WoE et IV **26**
5.1 Méthode . . . 26
5.2 Découpages retenus . . . 29
5.3 Variables à nombreuses modalités et regroupement des qualitatives (sujets 1.2.3, 1.2.4) . . . 29
5.4 WoE et IV . . . 30

6 Sélection des variables candidates **33**
6.1 Stabilité : quatre échantillons bootstrap (sujet 1.3.1) . . . 33
6.2 Pouvoir discriminant : V de Cramér et IV (sujet 1.3.2) . . . 36
6.3 Corrélations (sujet 1.3.3) . . . 37
6.4 Jeu final . . . 39

7 Régression logistique et sélection pas à pas **39**
7.1 Représentativité des échantillons (sujet 1.4.1) . . . 39
7.2 Spécification . . . 40
7.3 Modèle avec toutes les candidates (sujet 1.4.2) . . . 41
7.4 Sélection pas à pas (sujet 1.4.3) . . . 41
7.5 Modèle final . . . 43
7.6 Lecture des variables retenues . . . 44

8 Robustesse et probabilité de défaut **46**
8.1 Robustesse : 100 modèles bootstrap (sujet 1.5.1) . . . 46
8.2 Score et probabilité de défaut (sujet 1.5.2) . . . 47

9 XGBoost et comparaison des modèles **49**
9.1 Construction (sujet 1.5.3) . . . 49
9.2 Comparaison sur le même échantillon de test . . . 50
9.3 Quel modèle privilégier dans un contexte réglementé ? . . . 54

10 Conclusion **54**

A Démonstrations mathématiques **55**
A.1 Signe de l'IV et du PSI . . . 55
A.2 T de Tschuprow et nombre de classes . . . 56
A.3 Proportions d'outliers sous la loi normale et masquage . . . 56
A.4 Plafonnement, classes de quantiles et ratios . . . 56
A.5 Imputation hot-deck du montant . . . 57
A.6 WoE et régression logistique . . . 57
A.7 Maximum de vraisemblance et PD moyenne . . . 57
A.8 AUC et Accuracy Ratio . . . 58
A.9 Écarts-types asymptotiques et bootstrap . . . 58
A.10 Découpage stratifié . . . 58

1 Introduction

1.1 Contexte et objectif

Le risque de crédit est le risque qu'un emprunteur ne respecte pas ses engagements contractuels et cause une perte au prêteur. Les établissements financiers l'évaluent au moyen de modèles de notation interne qui estiment, pour chaque contrepartie, une *probabilité de défaut* (PD).

L'objectif du projet est de construire un modèle statistique de PD qui :

— identifie les principaux facteurs explicatifs du risque ;

— discrimine les emprunteurs défaillants des non-défaillants ;

— fournit une estimation fiable de la probabilité de défaut.

1.2 Données

Le fichier `LoanDetails.csv` décrit des prêts par leurs caractéristiques financières, comportementales et socio-économiques, ainsi que par leur statut final. Le sujet annonce 10 000 observations et 18 variables ; le fichier fourni compte **9 999 lignes et 19 colonnes** (2 identifiants, la variable cible et 16 variables explicatives). L'analyse porte sur le fichier réel.

1.3 Démarche générale

La démarche suit l'ordre du sujet, avec une adaptation : le découpage apprentissage/test est réalisé dès la fin du contrôle qualité.

1. **Qualité des données** : variables, cible, identifiants, faible variabilité, valeurs manquantes, cohérence ; corrections déterministes et dédoublonnage.
2. **Découpage apprentissage / test** (80 % / 20 %, stratifié, graine 42).
3. **Valeurs aberrantes** : détection, comparaison des méthodes, traitement.
4. **Variables dérivées** : DTI, CUR, ACR, ESR, IES.
5. **Discrétisation** (T de Tschuprow), **WoE et IV**.
6. **Sélection** : stabilité (bootstrap, PSI), V de Cramér, corrélations.
7. **Régression logistique** et sélection pas à pas.
8. **Robustesse** (100 bootstraps) et **probabilité de défaut**.
9. **XGBoost** et comparaison des modèles.

Pourquoi découper si tôt ? Toute statistique utilisée pour transformer les données (bornes de plafonnement, imputation, classes de discrétisation, WoE, sélection) doit être estimée sur le seul échantillon d'apprentissage. Sinon, l'échantillon de test contribue à construire le modèle et la performance mesurée sur ce test devient optimiste : c'est une *fuite d'information*. Le sujet impose d'ailleurs que les bootstraps de stabilité (section 1.3) soient tirés dans l'échantillon d'apprentissage. Seules des corrections *déterministes* (indépendantes de l'échantillon) sont appliquées avant le découpage.

1.4 Reproductibilité et traçabilité

— Tout le code est réuni dans le notebook `credit_risk.ipynb`. Les 17 modules de fonctions pures y sont définis (bloc A), les analyses forment les parties 1 à 8, et les 59 tests unitaires la partie 9. La documentation technique (`documentation.pdf`) décrit chaque fonction.

— Les tirages aléatoires utilisent `random_state = 42`.

— Chaque tableau de ce rapport est généré par le code (`resultats/tableaux_latex/`) ; chaque figure est enregistrée par le code (`resultats/figures/`).

2 Analyse de la qualité des données

Sujet 1.1, questions 1 à 4.
Code : `src.data_loading`, `src.data_quality`, `src.sampling`.
Notebook : partie 1 du notebook `credit_risk.ipynb`.

2.1 Variables disponibles et variable cible (question 1)

Lecture du fichier. Le fichier est lu en texte brut, sans conversion automatique des valeurs manquantes. On distingue ainsi les trois codages présents dans la source : la cellule vide, le jeton `NA` et le jeton `n/a`. Cette distinction permet de séparer les valeurs non applicables des valeurs réellement manquantes (section 2.3).

Nature des variables. Les 19 colonnes se répartissent en 2 identifiants, la cible et 16 variables explicatives. Parmi ces dernières :

— 8 sont quantitatives continues : montants, score, durées ;

— 4 sont quantitatives discrètes : nombres d'incidents et de comptes ;

— 4 sont qualitatives : *Term*, *Home Ownership*, *Purpose* (nominales) et *Years in current job* (ordinale).

Le tableau 1 résume les caractéristiques de la base brute. 6,01 % des cellules explicatives sont manquantes, et ces manquants sont concentrés sur trois variables. On compte aussi 99 lignes strictement dupliquées et seulement 9 827 identifiants de prêt distincts pour 9 999 lignes, ce qui signale un problème de doublons traité en section 2.4.1.

Tableau 1 – Principales caractéristiques de la base brute.

indicateur	valeur
Nombre d'observations	9 999
Nombre de colonnes	19
Identifiants	2
Variable cible	1
Variables explicatives	16
dont quantitatives continues	8
dont quantitatives discrètes	4
dont qualitatives	4
Nombre de défauts	2 307
Taux de défaut global	23,07 %
Cellules manquantes (explicatives)	9 620
Part de cellules manquantes	6,01 %
Lignes entièrement dupliquées	99
Identifiants de prêt distincts	9 827

Variable cible. La cible est *Loan Status*, le statut final du prêt : *Charged Off* (passé en perte) est le défaut, codé 1 ; *Fully Paid* (intégralement remboursé) est le non-défaut, codé 0. Le codage refuse toute autre modalité et toute valeur manquante, ce qui garantit une cible binaire et complète.

Tableau 2 – Distribution de la variable cible (base brute).

modalité	code	effectif	proportion
Fully Paid	0	7 692	76,93 %
Charged Off	1	2 307	23,07 %

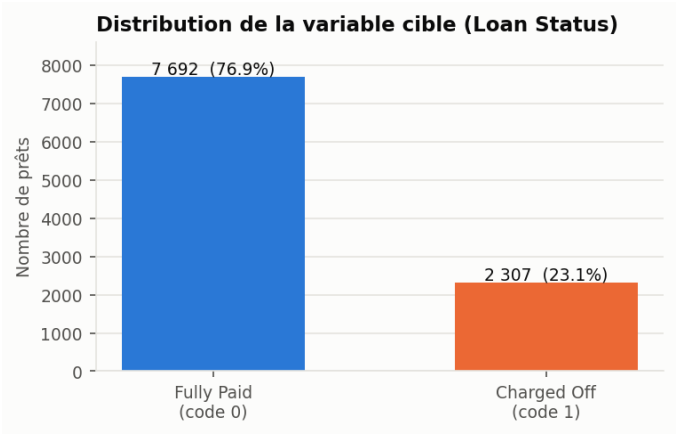


Figure 1 – Effectifs de la variable cible.

Le tableau 2 et la figure 1 donnent un taux de défaut de **23,07 %** (2 307 défauts sur 9 999 prêts), soit 3,33 non-défauts pour un défaut.

— **Le portefeuille n'est pas équilibré**, mais le déséquilibre reste modéré : la classe minoritaire représente près d'un quart des prêts, ce qui suffit à estimer une régression logistique.

— Un modèle qui prédirait toujours ń non-défaut ż classerait correctement 76,9 % des prêts. Le taux de bonne classification est donc trompeur. On évalue les modèles par l'AUC et l'Accuracy Ratio, et le découpage apprentissage/test est stratifié.

— Ce taux est élevé pour un portefeuille de détail : les PD estimées refléteront le niveau de l'échantillon et devraient être recalibrées avant tout usage sur un portefeuille réel.

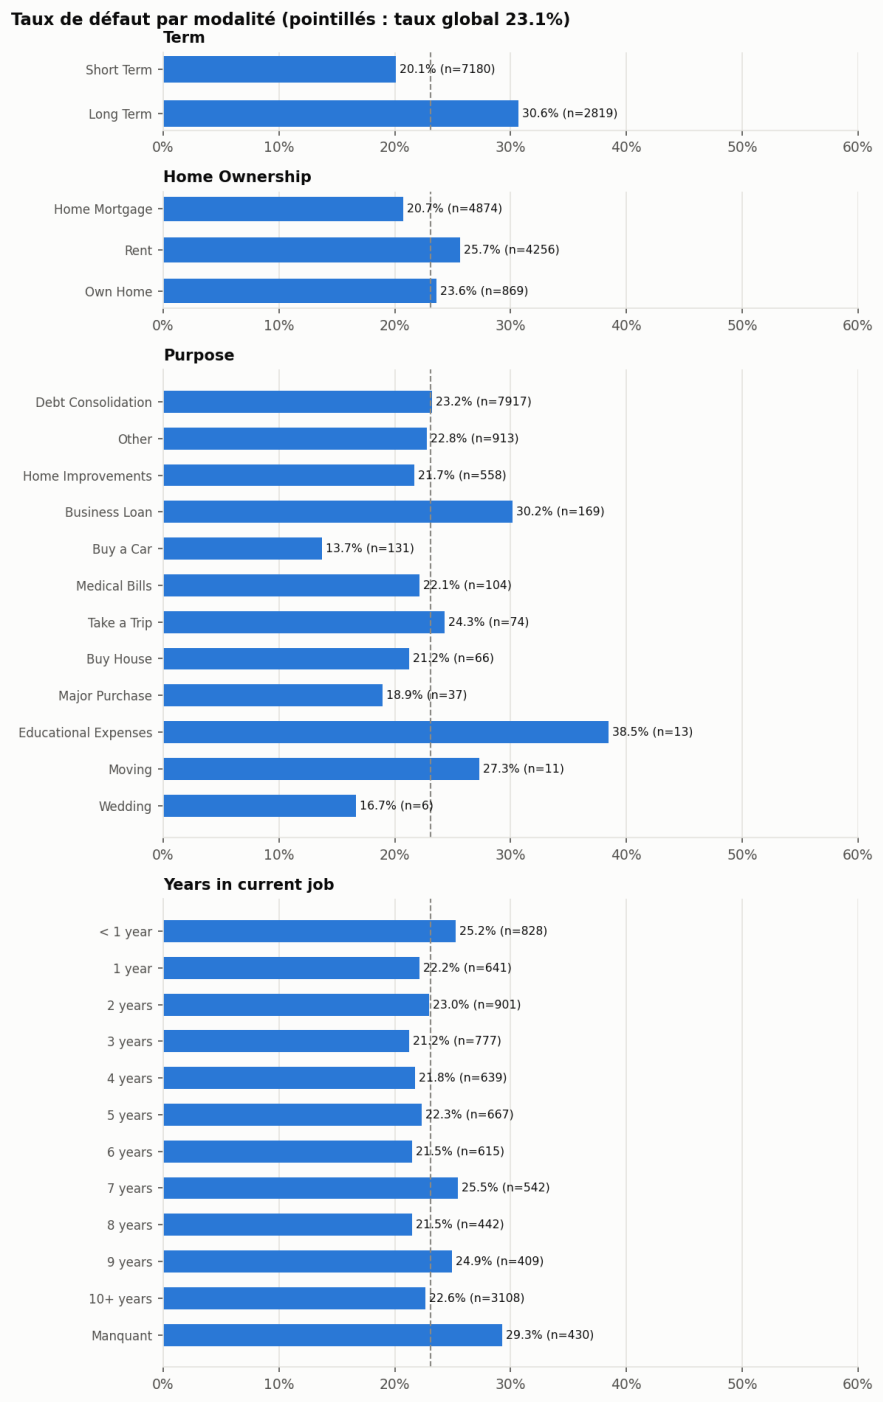


Figure 2 – Taux de défaut par modalité des variables qualitatives (libellés harmonisés). Pointillés : taux global.

La figure 2 donne un premier regard, purement descriptif, sur les variables qualitatives.

— **Term** : 30,6 % de défaut pour les prêts longs contre 20,1 % pour les prêts courts.

— **Home Ownership** : les locataires font plus défaut (25,7 %) que les titulaires d'un crédit immobilier (20,7 %).

— **Purpose** : 79 % des prêts relèvent de *Debt Consolidation*, et plusieurs motifs ne comptent que quelques prêts.

— **Years in current job** : aucun gradient avec l'ancienneté, mais la modalité `n/a` est la plus risquée (29,3 %).

2.2 Identifiants et variables à faible variabilité (question 2)

Identifiants.

— *Loan ID* et *Customer ID* prennent 9 827 valeurs distinctes pour 9 999 lignes, soit 98,3 % de valeurs uniques. Ils sont en relation strictement un-à-un : un client, un prêt.

— Un identifiant est attribué arbitrairement : il ne décrit pas l'emprunteur et n'a aucun lien causal avec le défaut. L'introduire dans le modèle reviendrait à apprendre l'échantillon par cœur, sans aucune capacité de généralisation.

— **Décision.** Les deux identifiants sont exclus des facteurs de risque. *Loan ID* est conservé comme clé technique pour la traçabilité.

Faible variabilité. La règle du sujet exclut toute variable dont une modalité dépasse 95 % des observations, sauf justification. Pour apprécier une justification statistique, on compare le taux de défaut de la modalité dominante à celui des autres observations par un test du χ^2 d'indépendance 2×2. La valeur manquante y est comptée comme une modalité.

Tableau 3 – Variables les plus concentrées : part et taux de défaut de la modalité dominante, p-value du χ^2.

variable	modalité dominante	part dominante	taux défaut dominante	taux défaut autres	p-value Khiš
Tax Liens	0.0	97,9 %	23,1 %	21,8 %	0,718
Bankruptcies	0.0	88,5 %	23,3 %	21,2 %	0,125
Number of Credit Problems	0.0	85,6 %	23,3 %	21,8 %	0,228
Purpose	Debt Consolidation	79,2 %	23,2 %	22,5 %	0,525
Term	Short Term	71,8 %	20,1 %	30,6 %	$<0{,}001$
Months since last delinquent	Manquant	53,0 %	23,5 %	22,5 %	0,251

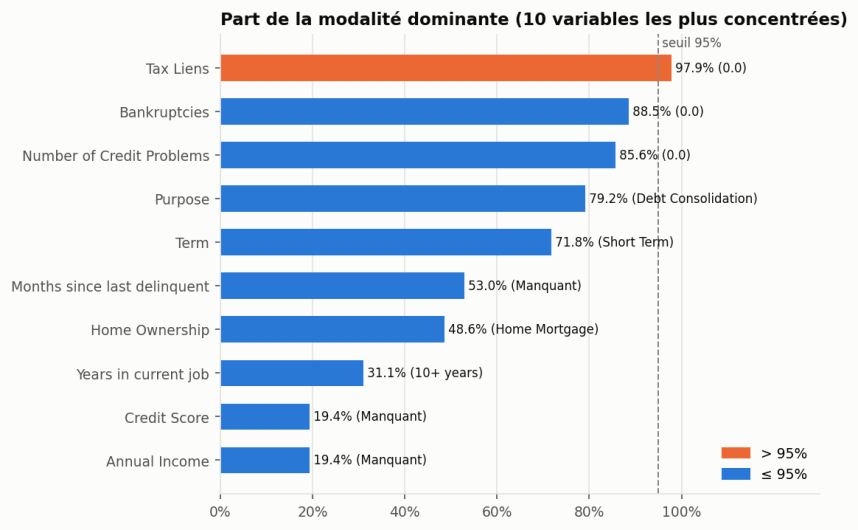


Figure 3 – Part de la modalité dominante (en orange : au-dessus du seuil de 95 %).

Le tableau 3 et la figure 3 conduisent aux décisions suivantes.

— **Tax Liens** est la seule variable au-dessus du seuil : 97,9 % de zéros. Les prêts avec un privilège fiscal ne sont pas plus risqués (21,8 % contre 23,1 %, $p = 0{,}72$) : ni le sens métier ni la statistique ne justifient de la garder. **Elle est exclue.**

— *Bankruptcies* (88,5 %) et *Number of Credit Problems* (85,6 %) restent sous le seuil et sont conservées à ce stade. Leur pouvoir discriminant sera mesuré en section 6.

2.3 Valeurs manquantes (question 3)

Tableau 4 – Valeurs manquantes par codage, nature, et taux de défaut selon que la valeur est manquante ou renseignée (base brute).

variable	n vide	n NA	n n/a	taux manquant	nature	taux défaut si manquant	taux défaut si renseigné	p-value Khiš
Months since last delinquent	0	5 298	0	53,0 %	Non applicable	23,5 %	22,5 %	0,251
Credit Score	1 937	0	0	19,4 %	Manquant réel	28,2 %	21,8 %	< 0,001
Annual Income	1 937	0	0	19,4 %	Manquant réel	28,2 %	21,8 %	< 0,001
Years in current job	0	0	430	4,3 %	Ambigu	29,3 %	22,8 %	0,002
Bankruptcies	0	17	0	0,2 %	Manquant réel	35,3 %	23,1 %	0,363
Tax Liens	0	1	0	0,0 %	Manquant réel	0,0 %	23,1 %	1,000

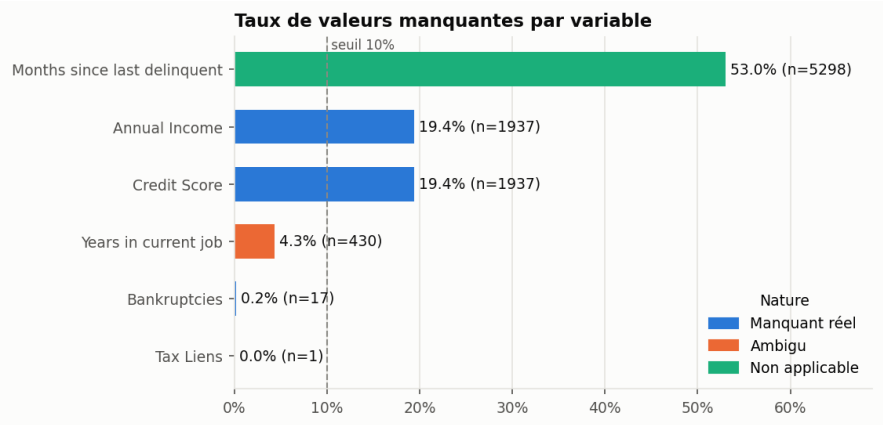


Figure 4 – Taux de valeurs manquantes par variable et nature du manquant (pointillés : seuil de 10 %).

Le tableau 4 et la figure 4 distinguent trois natures de valeurs manquantes.

— **Non applicable.** *Months since last delinquent* : 53,0 %, jeton `NA`. Aucun retard de paiement n'est enregistré, la durée depuis le dernier retard n'existe donc pas.

— **Manquant réel.** *Credit Score* et *Annual Income* : 19,4 %, cellule vide. Ces deux variables manquent *exactement sur les mêmes 1 937 lignes* (leur co-occurrence de manquants est égale à leur effectif) : c'est un défaut de collecte commun aux deux champs.

— **Ambigu.** *Years in current job* : 4,3 %, jeton `n/a`. La modalité peut signifier ń sans emploi salarié ż ou ń non renseigné ż.

— **Cas marginaux.** *Bankruptcies* (17 cas) et *Tax Liens* (1 cas).

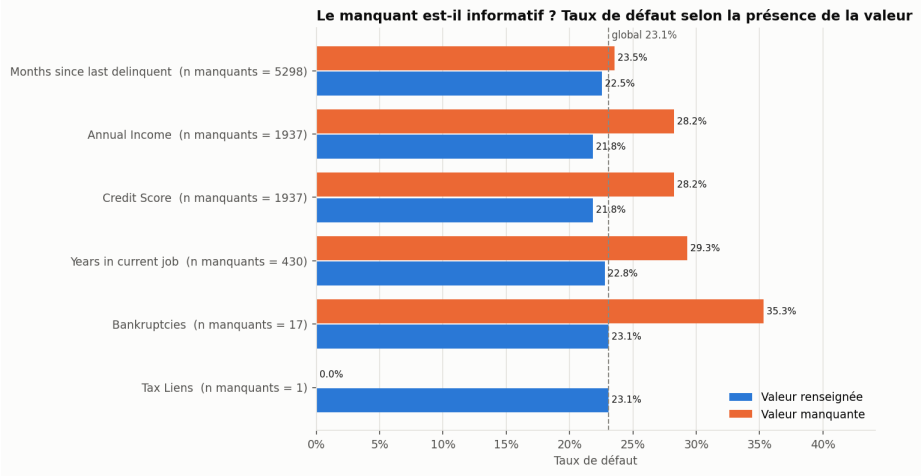


Figure 5 – Taux de défaut selon que la valeur est manquante ou renseignée (pointillés : taux global).

Le manquant est informatif. La figure 5 montre que l'absence de valeur est elle-même un signal de risque :

— quand *Credit Score* et *Annual Income* manquent, le taux de défaut atteint 28,2 % contre 21,8 % ($p < 0{,}001$) ;

— quand *Years in current job* vaut `n/a`, il atteint 29,3 % contre 22,8 % ($p = 0{,}002$).

Pour *Months since last delinquent*, en revanche, l'écart (23,5 % contre 22,5 %, $p = 0{,}25$) n'est pas significatif.

Une valeur manquante contient de l'information sur le risque lorsque son absence n'est pas due au hasard mais liée au profil de l'emprunteur, c'est-à-dire lorsque le mécanisme de manquant n'est pas ń complètement aléatoire ż. On rencontre trois cas :

— la situation décrite n'existe pas (aucun retard, aucun emploi salarié) ;

— l'emprunteur n'a pas fourni l'information (revenus non déclarés) ;

— le canal d'octroi ne collecte pas la donnée et présente un risque propre.

Décisions. Les trois variables à plus de 10 % de manquants sont **conservées**. Les traitements ci-dessous sont appris sur l'échantillon d'apprentissage lors de la discrétisation (section 5).

— une modalité ń Aucun retard ż pour *Months since last delinquent* ;

— une classe ń Manquant ż pour *Credit Score* et *Annual Income*. Une imputation par la médiane noierait le signal, et une suppression retirerait 19 % de la base en la biaisant vers les dossiers complets, moins risqués ;

— une modalité ń Non renseigné ż pour *Years in current job*, fusionnée à la discrétisation avec la classe de risque la plus proche si elle représente moins de 5 % des prêts ;

— une imputation par le mode pour les 17 manquants de *Bankruptcies*.

2.4 Contrôles de cohérence (question 4)

Tableau 5 – Contrôles de plages et de cohérence entre variables : effectif, part et taux de défaut des lignes en anomalie (base brute).

contrôle	n anomalies	part	taux défaut anomalies
Montant du prêt = 99 999 999 (valeur sentinelle)	1 136	11,36 %	0,0 %
Credit Score > 850 (hors échelle)	492	4,92 %	100,0 %
Credit Score < 300 (hors échelle)	0	0,00 %	
Revenu annuel ≤ 0	0	0,00 %	
Dette mensuelle < 0	0	0,00 %	
Dette mensuelle = 0	9	0,09 %	11,1 %
Dette annuelle > revenu annuel	0	0,00 %	
Ancienneté de crédit ≤ 0	0	0,00 %	
Ancienneté emploi > ancienneté de crédit	74	0,74 %	24,3 %
Dernier retard antérieur à l'historique de crédit	0	0,00 %	
Nombre de comptes ouverts = 0	0	0,00 %	
Crédit maximal autorisé = 0	66	0,66 %	19,7 %
Encours > crédit maximal autorisé	13	0,13 %	7,7 %
Faillites > incidents de crédit	0	0,00 %	
Privilèges fiscaux > incidents de crédit	0	0,00 %	
Credit Score et Annual Income manquants séparément	0	0,00 %	

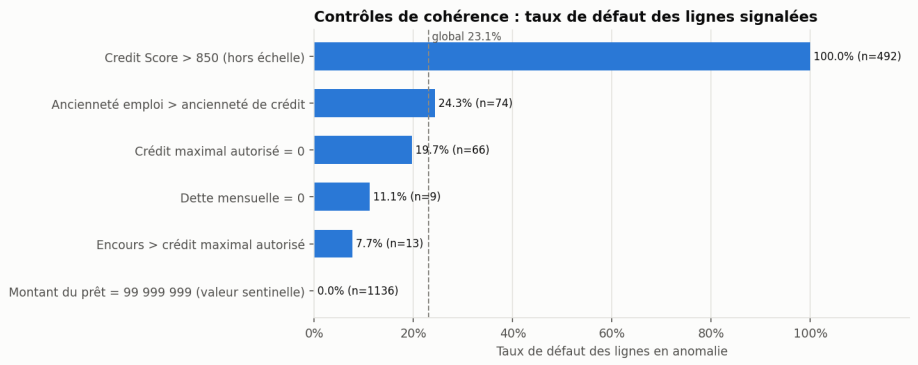


Figure 6 – Taux de défaut des lignes signalées par chaque contrôle en anomalie (pointillés : taux global).

Seize contrôles ont été appliqués (tableau 5). Dix ne signalent aucune anomalie : pas de revenu nul ni de dette négative, aucune dette annuelle supérieure au revenu, aucun score sous 300, aucun dernier retard antérieur à l'historique de crédit, des faillites jamais supérieures aux incidents, et un score et un revenu jamais manquants séparément.

La figure 6 isole **deux anomalies critiques**, qui révèlent directement l'issue du prêt.

— Les **1 136 montants égaux à 99 999 999** sont une valeur sentinelle (ń montant inconnu ż), portée *uniquement* par des prêts remboursés : 0 % de défaut.

— Les **492 Credit Score supérieurs à 850** sont portés *uniquement* par des défauts : 100 % de défaut.

Ces artefacts de constitution de la base produiraient un modèle quasi parfait en apparence mais inutilisable : au moment de l'octroi, rien ne permet de savoir si le prêt sera remboursé. Les autres anomalies sont plausibles et conservées :

— 74 ancienneté d'emploi supérieures à l'ancienneté de crédit ;

— 66 plafonds de crédit nuls, qui rendront CUR et ACR non définis ;

— 13 encours supérieurs au plafond ;

— 9 dettes mensuelles nulles.

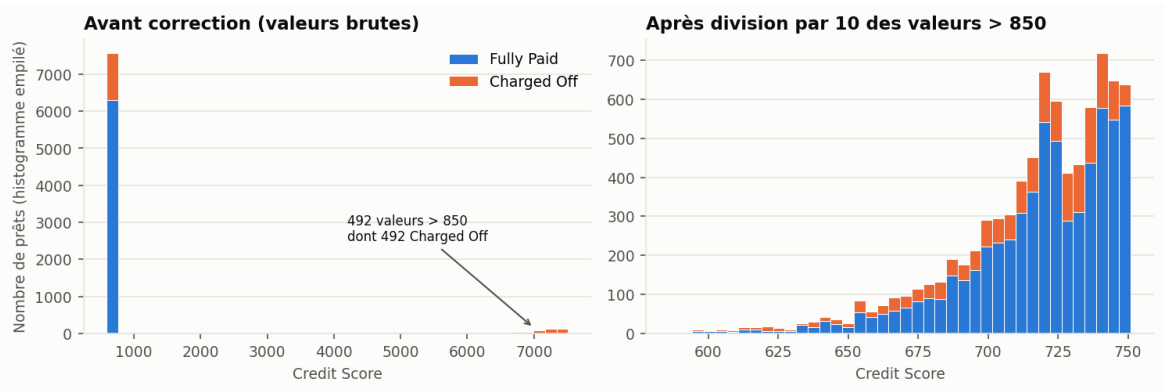


Figure 7 – Credit Score avant et après correction (histogrammes empilés par statut).

Correction du Credit Score. Les 492 valeurs supérieures à 850 sont toutes des multiples de 10. Une fois divisées par 10, elles couvrent 586 à 751, ce qui coïncide avec la plage des scores normaux (589 à 751). Leur médiane (718) est proche de celle des autres scores (723). L'hypothèse d'une erreur d'échelle (Œ10) est donc retenue et le score est divisé par 10.

La figure 7 montre l'effet de la correction : avant, un amas isolé de prêts entièrement en défaut ; après, une distribution continue où ces emprunteurs ne se distinguent plus.

Montant sentinelle. Le montant maximal hors sentinelle est 789 096 : la sentinelle est donc remplacée par une valeur manquante. Comme ces manquants sont tous des non-défauts, une modalité ń Manquant ż reproduirait la fuite d'information. Ils sont imputés par tirage dans la distribution de l'apprentissage (section 5).

2.4.1 Doublons et libellés

Tableau 6 – Contrôle des doublons.

contrôle	valeur
Lignes entièrement dupliquées (à supprimer)	99
Lignes après suppression des doublons exacts	9 900
Loan ID partagés par des lignes différentes	73
dont statut de défaut contradictoire	0
Prêts uniques (Loan ID distincts)	9 827

Le tableau 6 dénombre les doublons.

— **99 lignes sont des copies exactes.** Un prêt compté deux fois pèserait double dans l'estimation et pourrait apparaître à la fois en apprentissage et en test.

— **73 prêts apparaissent en deux versions différentes** :

  — 34 paires où une version porte le montant sentinelle ;

  — 39 paires où une version n'a ni score ni revenu.

  Le statut de défaut n'est jamais contradictoire entre les deux versions.

— **Les 172 prêts concernés sont tous des prêts remboursés.** La duplication est donc liée à la cible.

— **Règle retenue.** On garde la version la plus complète de chaque prêt.

Des libellés équivalents sont aussi harmonisés (`other` / `Other`, `HaveMortgage` / `Home Mortgage`, etc.) : *Purpose* passe de 15 à 12 modalités, *Home Ownership* de 4 à 3.

2.4.2 Traitements appliqués et synthèse

Tableau 7 – Traitements déterministes, dans leur ordre d'application.

étape	lignes avant	lignes après	cellules modifiées
Montant sentinelle 99 999 999 → NaN	9 999	9 999	1 136
Credit Score > 850 divisé par 10	9 999	9 999	492
Harmonisation des libellés	9 999	9 999	701
Doublons exacts supprimés, ligne la plus complète gardée par Loan ID	9 999	9 827	

Le tableau 7 retrace l'enchaînement des traitements, composés par une fonction de réduction :

1. la sentinelle devient une valeur manquante (1 136 cellules) ;
2. le score est corrigé (492 cellules) ;
3. les libellés sont harmonisés (701 cellules) ;
4. le dédoublonnage ramène la base de 9 999 lignes à **9 827 prêts uniques**.

Le taux de défaut passe à **23,48 %** : les 172 lignes retirées étant toutes des prêts remboursés, le nombre de défauts reste 2 307.

Tableau 8 – Synthèse par variable : taux de manquants avant et après traitement, traitement et décision.

variable	taux manquant brut	taux manquant après traitement	traitement	décision
Loan ID	0,0 %	0,0 %	Utilisé pour le dédoublonnage puis gardé comme index	Exclue des facteurs de risque
Customer ID	0,0 %	0,0 %	Supprimée	Exclue des facteurs de risque
Loan Status	0,0 %	0,0 %	Codée 1 = Charged Off (défaut), 0 = Fully Paid	Cible
Current Loan Amount	0,0 %	11,2 %	Sentinelle → NaN ; imputation par tirage dans la distribution de l'apprentissage (hot-deck), sans modalité ń Manquant ż	Conservée sous condition
Term	0,0 %	0,0 %	Aucun	Conservée
Credit Score	19,4 %	19,3 %	Division par 10 ; classe ń Manquant ż à la discrétisation	Conservée
Annual Income	19,4 %	19,3 %	Classe ń Manquant ż à la discrétisation	Conservée
Years in current job	4,3 %	4,3 %	Modalité ń Non renseigné ż (fusionnée à la discrétisation si < 5 %)	Conservée
Home Ownership	0,0 %	0,0 %	Fusion des deux libellés	Conservée
Purpose	0,0 %	0,0 %	Harmonisation ; regroupement par niveau de risque en phase de transformation	Conservée
Monthly Debt	0,0 %	0,0 %	Aucun	Conservée
Years of Credit History	0,0 %	0,0 %	Aucun	Conservée
Months since last delinquent	53,0 %	53,1 %	Modalité spécifique ń Aucun retard ż	Conservée
Number of Open Accounts	0,0 %	0,0 %	Aucun	Conservée
Number of Credit Problems	0,0 %	0,0 %	Aucun	Conservée
Current Credit Balance	0,0 %	0,0 %	Aucun à ce stade (valeurs plausibles, revues à l'étape outliers)	Conservée
Maximum Open Credit	0,0 %	0,0 %	Division par zéro gérée au feature engineering ; plafonnement au P99 (partie 2)	Conservée
Bankruptcies	0,2 %	0,2 %	Imputation par le mode, apprise sur l'apprentissage	Conservée
Tax Liens	0,0 %	0,0 %	Aucun	Exclue (faible variabilité)

Le tableau 8 répond à la demande de synthèse du sujet. Il donne, pour chaque variable, le taux de manquants avant et après traitement, le traitement appliqué et la décision. Après traitement, *Current Loan Amount* compte 11,2 % de manquants, issus de la sentinelle.

Une variable très prédictive mais de mauvaise qualité doit-elle être conservée ? Pas en l'état, pour trois raisons :

— son pouvoir prédictif peut n'être qu'un artefact, comme le montrent les deux anomalies critiques ;

— le modèle doit fonctionner sur de futurs dossiers, où l'artefact ne se reproduira pas ;

— un modèle réglementaire doit être traçable et stable.

On corrige donc l'anomalie quand son origine est établie, on neutralise l'artefact sinon, puis on réévalue la variable. On l'exclut si la qualité ne peut pas être restaurée.

2.5 Découpage apprentissage / test

Tableau 9 – Découpage apprentissage / test stratifié.

échantillon	effectif	part	n défauts	taux défaut
Population	9 827	100,0 %	2 307	23,48 %
Apprentissage	7 861	80,0 %	1 845	23,47 %
Test	1 966	20,0 %	462	23,50 %

La base est partagée en 80 % d'apprentissage et 20 % de test, avec une stratification sur la cible et `random_state = 42`. Le découpage est réalisé *avant* toute étape qui estime un paramètre, pour qu'aucune information du test n'intervienne dans la construction du modèle.

Le tableau 9 donne 7 861 prêts en apprentissage (1 845 défauts) et 1 966 en test (462 défauts). Les taux de défaut sont de 23,47 % et 23,50 %, à comparer à 23,48 % dans la population. La stratification garantit cet équilibre (annexe A.10).

3 Valeurs aberrantes

Sujet 1.1, questions 5 et 6.
Code : `src.outliers`, `src.plots_outliers`.
Notebook : partie 2 du notebook `credit_risk.ipynb`.

Toutes les statistiques de cette section sont calculées sur l'**échantillon d'apprentissage** (7 861 prêts). Le test ne sert qu'à vérifier que les bornes apprises se transposent. On analyse les 11 variables quantitatives conservées ; les valeurs manquantes sont ignorées, car elles reçoivent un traitement dédié.

3.1 Méthodes de détection

Une observation x_i est déclarée aberrante :

— par la **règle des trois écarts-types** si $|x_i - \bar{x}| > 3s$;

— par la **méthode IQR** si $x_i < Q_1 - 1{,}5\,\mathrm{IQR}$ ou $x_i > Q_3 + 1{,}5\,\mathrm{IQR}$, avec $\mathrm{IQR} = Q_3 - Q_1$.

Ces deux méthodes reposent sur des hypothèses différentes (tableau 10).

— Sous une loi normale, la règle des $3s$ signale en moyenne 0,27 % des observations, et la méthode IQR 0,70 %. Ses clôtures se situent en effet à $\mu \pm 2{,}698\,\sigma$ (démonstration en annexe A.3).

— Dès qu'une distribution est asymétrique ou à queue lourde, ces proportions ne tiennent plus.

Tableau 10 – Propriétés des deux méthodes de détection.

	Trois écarts-types	**IQR**
Statistiques utilisées	Moyenne, écart-type	Premier et troisième quartiles
Hypothèse implicite	Loi normale	Aucune
Sensibilité aux extrêmes	Forte : les extrêmes gonflent s (masquage)	Faible : les quartiles sont robustes
Loi asymétrique	Borne basse négative, borne haute très éloignée	Signale une part importante de la queue longue
Variable avec $Q_1 = Q_3$	Fonctionne	Dégénère : toute valeur différente de Q_1 est signalée

3.2 Distributions

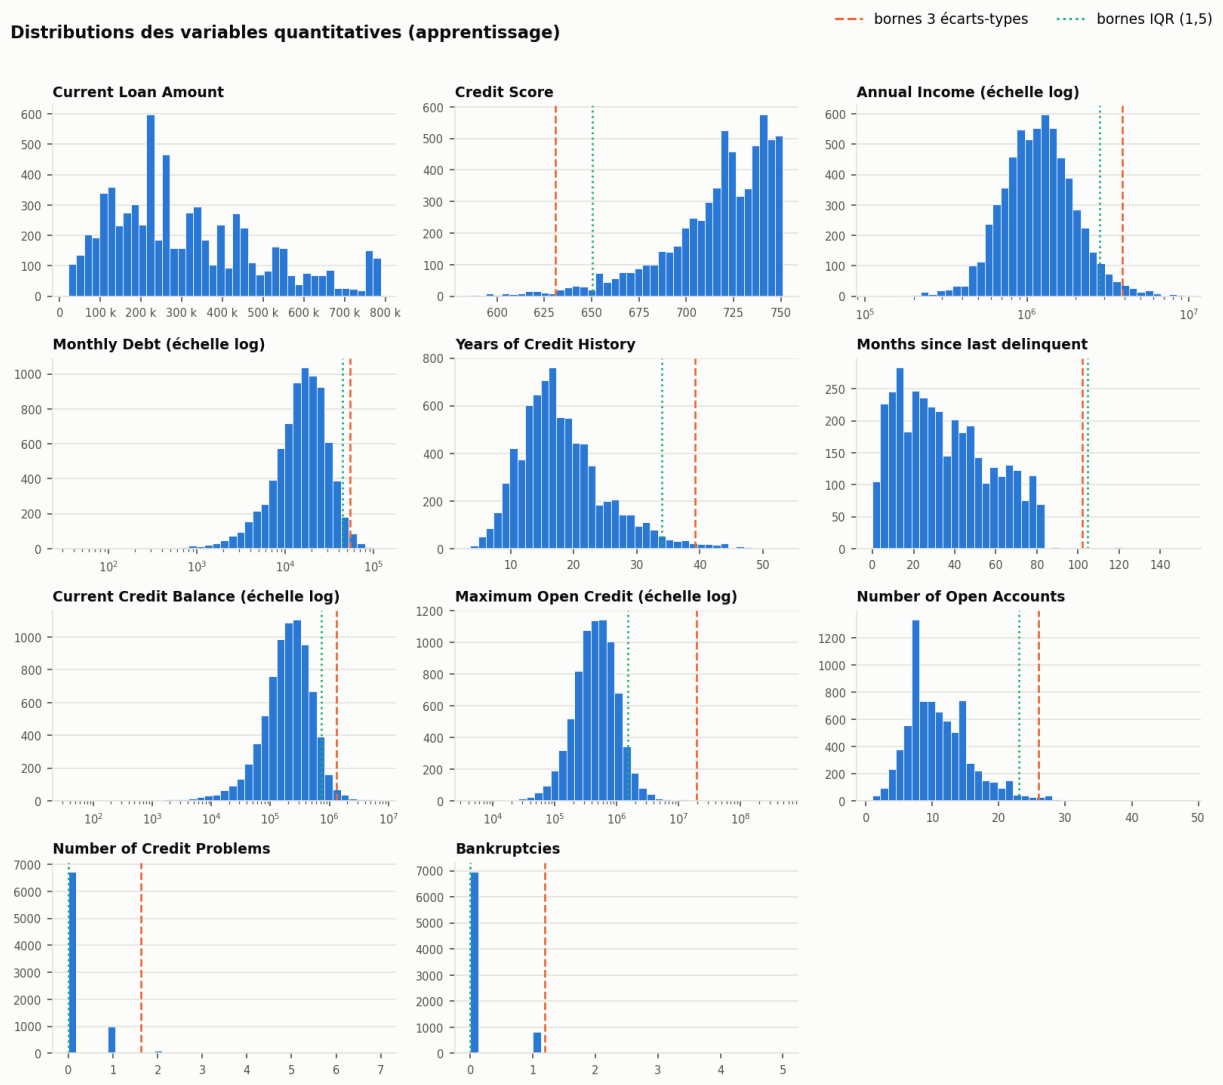


Figure 8 – Distributions sur l'apprentissage, avec les bornes des deux méthodes (montants en échelle logarithmique ; une borne hors de la plage observée n'est pas tracée).

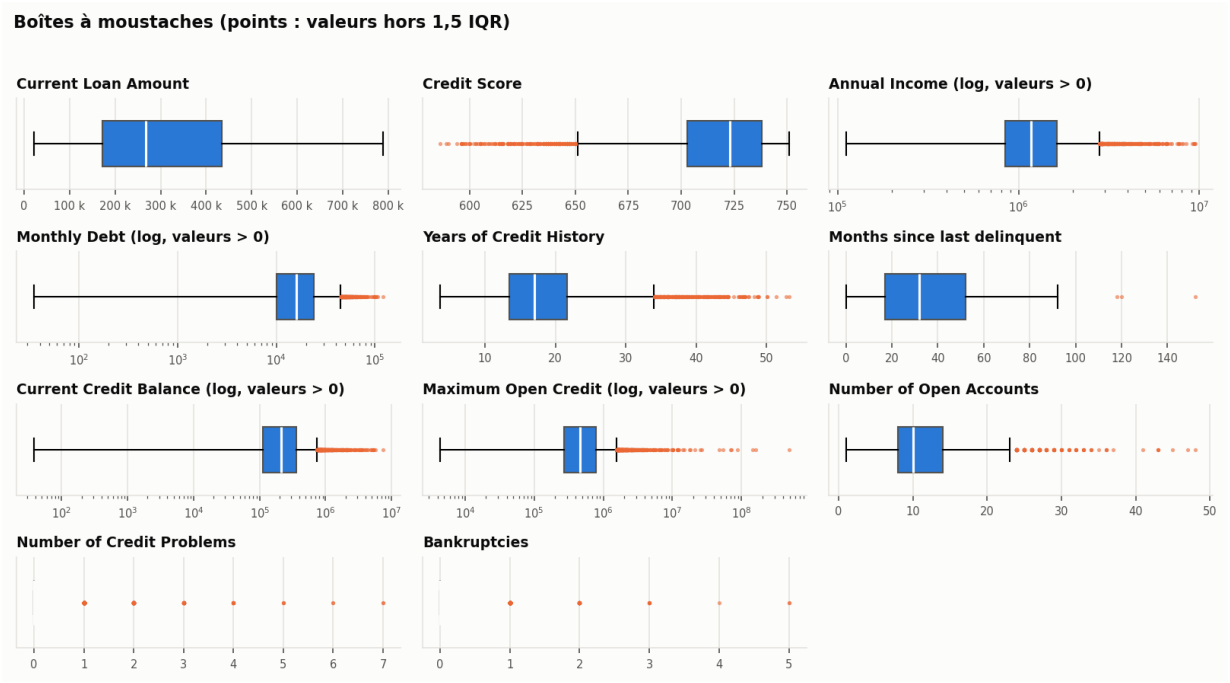


Figure 9 – Boîtes à moustaches : les points au-delà des moustaches (1,5 IQR) sont les outliers au sens IQR.

Les figures 8 et 9 font apparaître trois profils de distribution.

— **Montants à forte asymétrie positive** :

  — *Annual Income* : asymétrie 3,0, kurtosis 15,9 ;

  — *Current Credit Balance* : asymétrie 6,7, kurtosis 79 ;

  — *Maximum Open Credit* : asymétrie 63, kurtosis 4 613. Son maximum (489 M) vaut 135 fois son 99e percentile (3,6 M), et son écart-type (6,3 M) vaut 14 fois sa médiane (0,46 M).

  En échelle logarithmique, ces montants prennent une forme proche d'une cloche : leur asymétrie tient surtout à leur nature multiplicative.

— **Credit Score** : asymétrie négative ($-1{,}3$), avec une queue de scores bas.

— **Comptages concentrés sur 0** (*Number of Credit Problems*, *Bankruptcies*) : $Q_1 = Q_3 = 0$, la boîte se réduit à un trait.

3.3 Résultats des deux méthodes

Tableau 11 – Bornes et outliers détectés par chaque méthode (apprentissage).

variable	méthode	borne inf	borne sup	n outliers	part	taux défaut outliers
Current Loan Amount	3 écarts-types	-246 865,49	869 820,63	0	0,0 %	
Current Loan Amount	IQR	-220 709,50	826 622,50	0	0,0 %	
Credit Score	3 écarts-types	630,94	801,63	91	1,4 %	45,1 %
Credit Score	IQR	650,50	790,50	220	3,5 %	36,8 %
Annual Income	3 écarts-types	-1 163 068,73	3 887 924,64	107	1,7 %	15,9 %
Annual Income	IQR	-335 506,75	2 808 461,25	309	4,9 %	12,9 %
Monthly Debt	3 écarts-types	-17 420,07	54 031,50	115	1,5 %	15,7 %
Monthly Debt	IQR	-10 911,89	44 852,35	249	3,2 %	20,9 %
Years of Credit History	3 écarts-types	-2,78	39,30	109	1,4 %	16,5 %
Years of Credit History	IQR	1,20	34,00	249	3,2 %	19,3 %
Months since last delinquent	3 écarts-types	-31,28	102,17	3	0,1 %	33,3 %
Months since last delinquent	IQR	-35,50	104,50	3	0,1 %	33,3 %
Current Credit Balance	3 écarts-types	-751 362,82	1 331 651,27	98	1,2 %	9,2 %
Current Credit Balance	IQR	-268 099,50	741 408,50	404	5,1 %	20,0 %
Maximum Open Credit	3 écarts-types	-18 198 980,59	19 780 616,19	11	0,1 %	18,2 %
Maximum Open Credit	IQR	-493 207,00	1 542 497,00	443	5,6 %	16,3 %
Number of Open Accounts	3 écarts-types	-3,89	25,99	109	1,4 %	26,6 %
Number of Open Accounts	IQR	-1,00	23,00	177	2,3 %	23,7 %
Number of Credit Problems	3 écarts-types	-1,28	1,63	154	2,0 %	22,7 %
Number of Credit Problems	IQR	0,00	0,00	1 138	14,5 %	22,6 %
Bankruptcies	3 écarts-types	-0,95	1,19	50	0,6 %	20,0 %
Bankruptcies	IQR	0,00	0,00	886	11,3 %	21,9 %

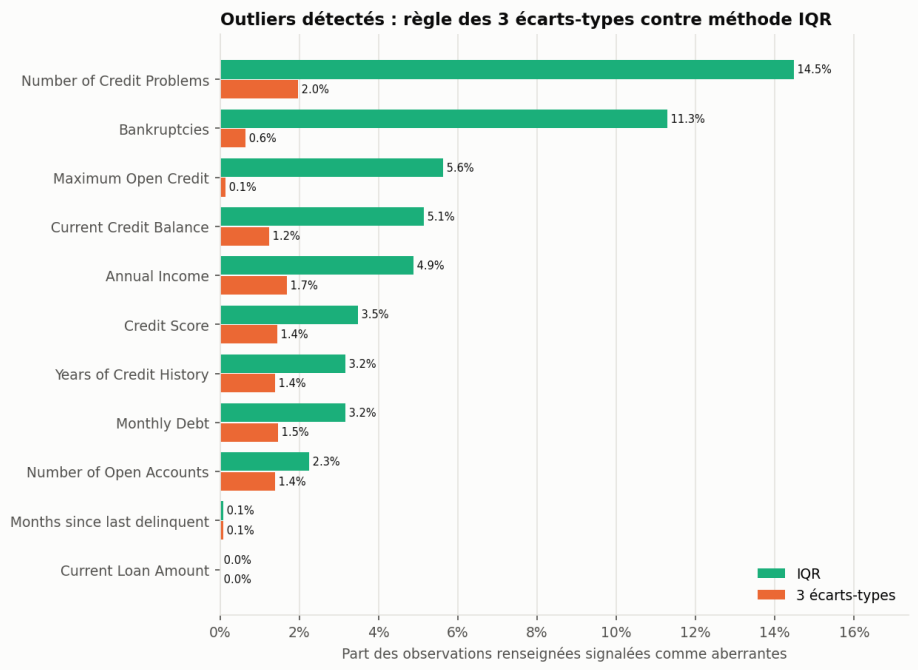


Figure 10 – Part des observations signalées, par variable et par méthode.

Tableau 12 – Recouvrement des deux méthodes : observations signalées par les deux, par une seule, indice de Jaccard.

variable	les deux	seulement 3 écarts types	seulement IQR	jaccard
Current Loan Amount	0	0	0	
Credit Score	91	0	129	0,41
Annual Income	107	0	202	0,35
Monthly Debt	115	0	134	0,46
Years of Credit History	109	0	140	0,44
Months since last delinquent	3	0	0	1,00
Current Credit Balance	98	0	306	0,24
Maximum Open Credit	11	0	432	0,02
Number of Open Accounts	109	0	68	0,62
Number of Credit Problems	154	0	984	0,14
Bankruptcies	50	0	836	0,06

Le tableau 11 et la figure 10 montrent que la méthode IQR signale toujours au moins autant d'observations que la règle des $3s$, souvent deux à quatre fois plus. Par exemple : 404 contre 98 pour *Current Credit Balance*, 309 contre 107 pour *Annual Income*.

Le tableau 12 apporte un constat central : les outliers à $3s$ forment **toujours un sous-ensemble** des outliers IQR. La colonne ń seulement 3 écarts types ż est nulle pour toutes les variables.

Effet de masquage. Pour *Maximum Open Credit*, quelques plafonds démesurés portent l'écart-type à 6,3 M. La borne $\bar{x} + 3s$ atteint alors 19,8 M et ne retient que 11 valeurs, contre 443 pour la méthode IQR (indice de Jaccard 0,02).

Les extrêmes se cachent ainsi eux-mêmes en dilatant l'échelle de mesure. L'inégalité de Samuelson en donne la forme extrême : dans un échantillon de taille n, aucune observation ne peut s'écarter de la moyenne de plus de $s\,(n-1)/\sqrt{n}$. Dans un petit échantillon, une valeur même gigantesque peut donc ne jamais être signalée (annexe A.3). C'est le cas testé par `test_sigma_rule_masks_extreme_value_in_small_sample`.

Dégénérescence de l'IQR. Sur les comptages, l'IQR est nul : la méthode signale tout emprunteur ayant au moins un incident (1 138 prêts, soit 14,5 %) ou au moins une faillite (886, soit 11,3 %). Ces valeurs sont pourtant réelles.

Méthode retenue.

— **Variables continues : repérage par l'IQR.** La méthode est robuste au masquage et ne suppose pas de loi normale. Une observation repérée n'est pas pour autant une erreur, ce qu'on examine ci-dessous.

— **Comptages : aucune des deux méthodes.** Ils seront regroupés en classes lors de la discrétisation.

3.4 Valeurs extrêmes : erreurs ou observations réelles ?

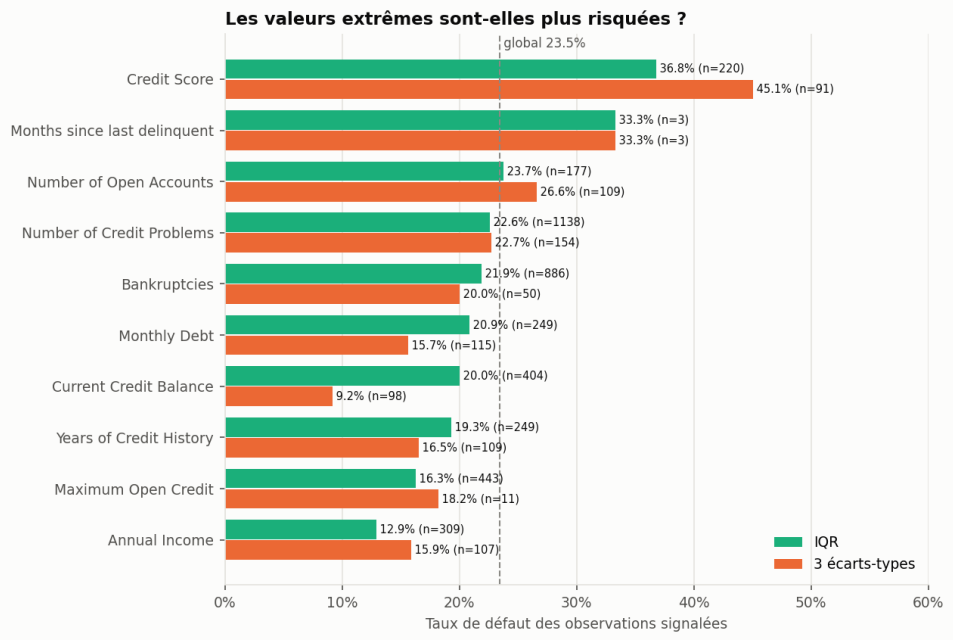


Figure 11 – Taux de défaut des observations signalées, par méthode. Pointillés : taux de l'apprentissage (23,5 %).

La figure 11 montre que les extrêmes portent de l'information sur le risque :

— les scores bas sont nettement plus risqués : 45,1 % de défaut pour les outliers à $3s$, 36,8 % pour les outliers IQR ;

— les très hauts revenus sont moins risqués : 12,9 % à 15,9 % ;

— les très gros encours le sont aussi : 9,2 % pour les outliers à $3s$.

Supprimer ou imputer ces valeurs détruirait précisément ce signal.

Critères d'erreur. Une valeur est jugée erronée si elle vérifie deux critères :

1. elle est hors des clôtures de Tukey ń très éloignées ż ($k = 3$) calculées sur le *logarithme* du montant, donc extrême en ordre de grandeur ;
2. elle est incohérente avec une autre variable.

Tableau 13 – Plafonds de crédit extrêmes en ordre de grandeur et ratio au revenu annuel (case vide : revenu manquant).

Maximum Open Credit	Annual Income	ratio
21 372 428	1 520 304	14,1
25 368 464	1 064 019	23,8
26 946 898	1 998 496	13,5
47 844 500		
54 484 386	3 356 255	16,2
69 918 046	1 167 588	59,9
71 309 216		
86 599 480	2 229 574	38,8
145 907 344	3 355 970	43,5
162 187 168	8 426 880	19,2
489 343 206	1 668 618	293,3

Le tableau 13 isole 11 plafonds de 21 M à 489 M, qui représentent **13 à 293 fois le revenu annuel**. Sur l'apprentissage, ce ratio vaut 0,40 en médiane et 2,31 au 99e percentile. Aucun établissement n'accorde une ligne de crédit renouvelable de plusieurs dizaines d'années de revenu : ce sont des **erreurs probables** de saisie ou d'unité.

Les petites valeurs de *Monthly Debt* et de *Current Credit Balance*, ainsi que les zéros, restent plausibles : dette presque nulle, encours soldé, ligne fermée.

3.5 Stratégies de traitement (question 6)

Tableau 14 – Impact des stratégies sur *Maximum Open Credit* (apprentissage).

stratégie	n conservées	valeurs modifiées	moyenne	écart type	asymétrie	max
Aucun traitement	7 861	0	790 818	6 329 933	62,98	489 343 206
Suppression (3 écarts-types)	7 850	0	638 897	801 266	8,77	18 366 788
Suppression (IQR)	7 418	0	512 859	330 383	0,86	1 542 420
Imputation médiane (IQR)	7 861	443	508 432	321 448	0,93	1 542 420
Plafonnement (IQR)	7 861	443	570 883	399 231	0,99	1 542 497
Plafonnement (P99)	7 861	79	617 357	561 995	2,65	3 617 451
Transformation log(1+x)	7 861	7 806	13	1	-5,66	20

Le tableau 14 compare sept stratégies sur *Maximum Open Credit* ; les trois autres montants suivent le même schéma.

- **Suppression (IQR)** : retire 443 lignes ; l'asymétrie passe de 63 à 0,86.
- **Imputation par la médiane** : donne une valeur moyenne à de vrais gros plafonds et resserre artificiellement la distribution.
- **Plafonnement à la borne IQR** : écrase 5,6 % de la distribution.
- **Transformation** $\log(1+x)$: crée une asymétrie inverse ($-5{,}7$), à cause des zéros.
- **Plafonnement au 99e percentile** : ne modifie que 1 % des valeurs, ne retire aucune ligne et ramène l'écart-type de 6,3 M à 0,56 M.

Tableau 15 – Lignes conservées si l'on supprime toute ligne signalée sur au moins une variable.

méthode	lignes conservées	part conservée	défauts conservés	taux défaut
Aucune suppression	7 861	100,0 %	1 845	23,47 %
Suppression (3 écarts-types)	7 176	91,3 %	1 690	23,55 %
Suppression (IQR)	5 457	69,4 %	1 307	23,95 %

Le tableau 15 chiffre le coût de la suppression. Avec la méthode IQR, il ne reste que 5 457 prêts sur 7 861 (69,4 %), et 538 défauts sont perdus. Avec les $3s$, il en reste 91,3 %. Dans les deux cas, le taux de défaut est modifié (23,95 % et 23,55 %, contre 23,47 %) : l'échantillon cesse d'être représentatif de la population à noter.

Effet sur la discrétisation. Le plafonnement au P99 préserve l'ordre des observations. Les classes de déciles sont donc strictement identiques avant et après traitement, ce qui est vérifié pour les quatre montants (démonstration en annexe A.4).

En revanche, plafonner séparément le numérateur et le dénominateur d'un ratio en modifie la valeur. Les ratios de la section 4 sont donc calculés sur les montants non plafonnés.

3.6 Traitement retenu

Les quatre montants à forte asymétrie (*Annual Income*, *Monthly Debt*, *Current Credit Balance*, *Maximum Open Credit*) sont plafonnés à leur 99e percentile, appris sur l'apprentissage et appliqué tel quel au test.

Tableau 16 – Bornes de plafonnement (P99 de l'apprentissage) et valeurs plafonnées par échantillon.

variable	borne sup	n plafonnées apprentissage	n plafonnées test	part apprentissage	part test
Annual Income	4 685 501	64	18	1,01 %	1,13 %
Monthly Debt	58 126	79	28	1,00 %	1,42 %
Current Credit Balance	1 511 306	79	24	1,00 %	1,22 %
Maximum Open Credit	3 617 451	79	21	1,00 %	1,07 %

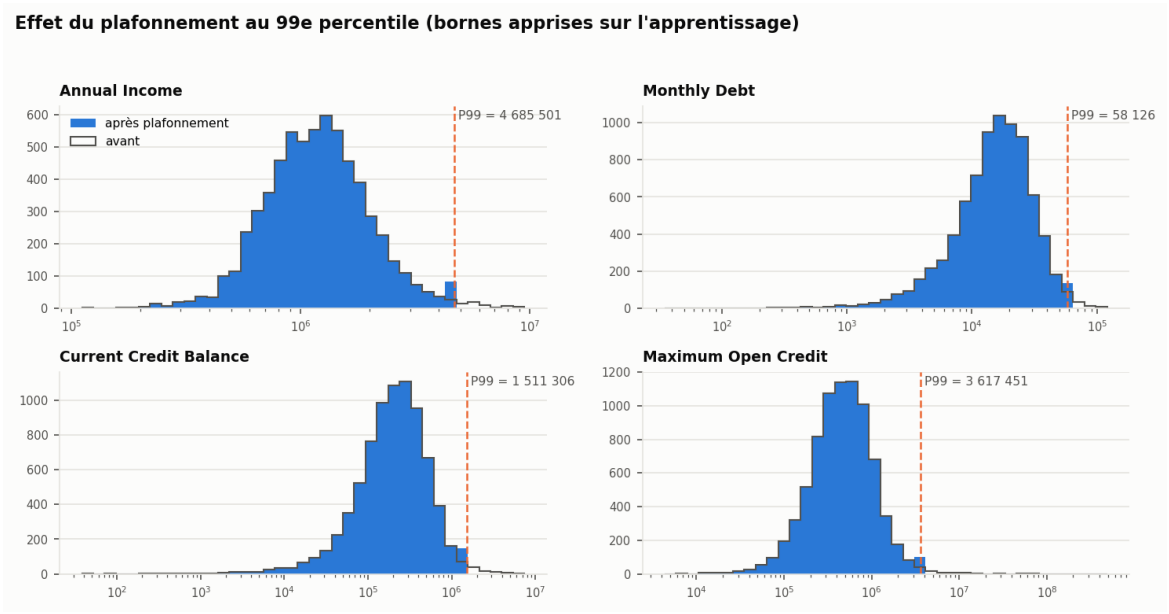


Figure 12 – Distributions avant (contour) et après (barres) plafonnement, en échelle logarithmique.

Le tableau 16 montre que la part de valeurs plafonnées dans le test (1,1 à 1,4 %) est proche du 1 % de l'apprentissage : les bornes se transposent. La figure 12 confirme que seule l'extrémité droite des distributions est modifiée : les valeurs au-delà du P99 se reportent sur la borne.

Tableau 17 – Synthèse des décisions par variable.

variable	n 3 écarts types	n IQR	origine	traitement
Current Loan Amount	0	0	Aucun outlier (sentinelle déjà retirée)	Aucun
Credit Score	91	220	Valeurs réelles (queue basse)	Aucun
Annual Income	107	309	Valeurs réelles (queue haute)	Plafonnement au P99 appris sur train
Monthly Debt	115	249	Valeurs réelles (queue haute)	Plafonnement au P99 appris sur train
Years of Credit History	109	249	Valeurs réelles	Aucun
Months since last delinquent	3	3	Valeurs réelles	Aucun
Current Credit Balance	98	404	Valeurs réelles (queue haute)	Plafonnement au P99 appris sur train
Maximum Open Credit	11	443	Erreurs probables (ordre de grandeur) et queue haute réelle	Plafonnement au P99 appris sur train
Number of Open Accounts	109	177	Valeurs réelles	Aucun
Number of Credit Problems	154	1 138	Valeurs réelles (comptage rare)	Regroupement à la discrétisation
Bankruptcies	50	886	Valeurs réelles (comptage rare)	Regroupement à la discrétisation

Le tableau 17 récapitule les décisions.

— Aucune observation n'est supprimée et aucune variable n'est exclue pour cause d'outliers.

— Les 11 plafonds aberrants sont neutralisés par le plafonnement.

— Les scores bas, informatifs, sont conservés tels quels.

— Les comptages rares seront regroupés lors de la discrétisation.

4 Variables dérivées

Sujet 1.2.1.

Code : `src.features`, `src.plots_features`.

Notebook : partie 3 du notebook `credit_risk.ipynb`.

4.1 Définitions et interprétation économique

Le sujet demande de construire cinq variables qui décrivent plus directement la capacité de remboursement, l'endettement et la stabilité financière des emprunteurs :

$$\text{DTI} = \frac{12 \times \text{Monthly Debt}}{\text{Annual Income}}, \qquad \text{CUR} = \frac{\text{Current Credit Balance}}{\text{Maximum Open Credit}},$$

$$\text{ACR} = \frac{\text{Maximum Open Credit} - \text{Current Credit Balance}}{\text{Maximum Open Credit}}, \qquad \text{ESR} = \frac{\text{Years in current job}}{\text{Years of Credit History}},$$

$$\text{IES} = \text{Annual Income} \times \text{Years in current job}.$$

Tableau 18 – Signification économique et effet attendu sur la probabilité de défaut.

variable	formule	signification	effet attendu
DTI	12 × Monthly Debt / Annual Income	Part du revenu annuel absorbée par le service de la dette : mesure la capacité de remboursement.	Plus le DTI est élevé, moins il reste de revenu pour absorber un choc : PD croissante.
CUR	Current Credit Balance / Maximum Open Credit	Taux d'utilisation des lignes de crédit renouvelables : dépendance au crédit.	Une utilisation proche du plafond signale une tension de trésorerie : PD croissante.
ACR	(Maximum Open Credit − Current Credit Balance) / Maximum Open Credit	Part du plafond encore disponible : réserve de liquidité mobilisable (ACR = 1 − CUR).	Une réserve importante permet de faire face à un imprévu : PD décroissante.
ESR	Years in current job / Years of Credit History	Ancienneté dans l'emploi rapportée à l'ancienneté de crédit : stabilité professionnelle relative.	Un emploi stable sur une grande partie de la vie de crédit rassure : PD décroissante.
IES	Annual Income × Years in current job	Revenu pondéré par sa durabilité : niveau et stabilité des ressources.	Un revenu élevé et ancien est plus sûr : PD décroissante.

Le tableau 18 reprend, pour chaque variable, sa formule, sa signification économique et l'effet attendu sur la PD. Ces effets attendus sont ensuite confrontés aux données (tableau 23).

— **DTI : capacité de remboursement.** Part du revenu annuel consacrée à la dette. Plus elle est élevée, plus la marge pour absorber un choc est faible : on attend une PD croissante.

— **CUR : dépendance au crédit renouvelable.** Un emprunteur proche de son plafond finance probablement des dépenses courantes à crédit : on attend une PD croissante.

— **ACR : réserve de liquidité.** Part du plafond encore mobilisable : on attend une PD décroissante. Dès que le plafond est non nul, ACR = 1 − CUR : les deux variables portent la même information.

— **ESR : stabilité professionnelle relative.** Ancienneté d'emploi rapportée à la durée de la vie de crédit : on attend une PD décroissante.

— **IES : niveau et durabilité du revenu.** Un revenu élevé et ancien est plus sûr : on attend une PD décroissante.

Conversion de l'ancienneté d'emploi. *Years in current job* est ordinale. On la convertit en nombre d'années : `< 1 year` → 0, `10+ years` → 10, `n/a` → non défini. Deux limites en découlent :

— la modalité `10+ years` est censurée et concerne 2 450 prêts (31 % de l'apprentissage) ;

— 671 prêts reçoivent une ancienneté nulle, ce qui annule leur ESR et leur IES.

4.2 Construction

Ratios calculés sur les montants non plafonnés. Plafonner séparément le numérateur et le dénominateur d'un ratio en modifie le rapport.

Exemple pédagogique : un plafond de 5 M et un encours de 4,9 M donnent CUR = 0,98. Après plafonnement séparé à 3,6 M et 1,5 M, on obtiendrait CUR ≈ 0,42.

Sur l'apprentissage, calculer les ratios sur les montants plafonnés modifierait une centaine de valeurs (106 DTI et 101 CUR et ACR), avec un écart relatif médian de 14 à 21 %, qui peut aller jusqu'à un facteur 4 pour CUR (tableau 19). L'annexe A.4 explique pourquoi le plafonnement, sans effet sur les classes de quantiles d'une variable, en a un sur un ratio. Les ratios sont donc calculés sur les montants issus du contrôle qualité. Le plafonnement de la section 3 ne s'applique qu'aux montants utilisés seuls.

Tableau 19 – Déformation des ratios s'ils étaient calculés sur les montants plafonnés (apprentissage).

variable	lignes modifiées	écart relatif médian	écart relatif max
DTI	106	14,1 %	101,9 %
CUR	101	20,6 %	407,7 %
ACR	101	19,3 %	296,8 %
ESR	0		
IES	59	19,5 %	50,3 %

Divisions par zéro et valeurs non définies. Une division par un dénominateur nul ou manquant renvoie une valeur *non définie*, jamais une valeur infinie ou arbitraire. Un test unitaire (partie 9 du notebook) le vérifie, et aucune valeur infinie n'est produite sur les données. Le tableau 20 détaille les causes.

Tableau 20 – Valeurs non définies par variable et par cause.

variable	cause	n apprentissage	part apprentissage	n test	part test
ACR	plafond erroné (ordre de grandeur)	11	0,1 %	3	0,2 %
ACR	plafond nul	55	0,7 %	10	0,5 %
ACR	total non défini	66	0,8 %	13	0,7 %
CUR	plafond erroné (ordre de grandeur)	11	0,1 %	3	0,2 %
CUR	plafond nul	55	0,7 %	10	0,5 %
CUR	total non défini	66	0,8 %	13	0,7 %
DTI	revenu manquant	1 529	19,5 %	369	18,8 %
DTI	revenu nul	0	0,0 %	0	0,0 %
DTI	total non défini	1 529	19,5 %	369	18,8 %
ESR	ancienneté d'emploi manquante	343	4,4 %	80	4,1 %
ESR	ancienneté de crédit nulle	0	0,0 %	0	0,0 %
ESR	total non défini	343	4,4 %	80	4,1 %
IES	ancienneté d'emploi manquante	343	4,4 %	80	4,1 %
IES	revenu manquant	1 529	19,5 %	369	18,8 %
IES	total non défini	1 806	23,0 %	427	21,7 %

— **DTI.** Aucun revenu nul n'est observé (le cas est néanmoins géré). Les 1 529 valeurs non définies (19,4 %) héritent des revenus manquants.

— **ESR.** L'ancienneté de crédit n'est jamais nulle (minimum 3,6 ans). Les 343 valeurs non définies proviennent de la modalité `n/a` de l'ancienneté d'emploi.

— **IES.** Ce produit n'est pas défini dès qu'un des deux facteurs manque : 1 806 prêts (23,0 %).

— **CUR et ACR.** C'est le seul vrai problème de dénominateur nul : 55 prêts ont un plafond de crédit nul (tableau 21), dont 47 sans encours (aucune ligne de crédit ouverte) et 8 avec un encours positif (incohérence). Remplacer le ratio par 0 ou par 1 affirmerait une utilisation nulle ou totale qui n'a pas de sens : il est laissé non défini.

Les 11 plafonds identifiés comme erronés à la section 3 sont aussi considérés comme inconnus pour ces deux ratios. Calculé avec un plafond de 489 M, le CUR serait presque nul, et l'emprunteur paraîtrait à tort ne pas utiliser son crédit. La borne d'erreur (18,4 M) est apprise sur l'apprentissage.

Tableau 21 – Prêts sans plafond de crédit (apprentissage).

situation	**n**	**taux défaut**
plafond nul, encours nul	47	23,4 %
plafond nul, encours > 0	8	12,5 %
plafond > 0	7 806	23,5 %

Le tableau 21 montre que les 47 prêts sans ligne de crédit ont un taux de défaut (23,4 %) égal à la moyenne. Celui des 8 prêts incohérents (12,5 %) repose sur un effectif trop faible pour être interprété.

Les valeurs non définies formeront une classe dédiée lors de la discrétisation. Celle de CUR et ACR (0,8 % des prêts) sera regroupée avec la classe de risque la plus proche, conformément au seuil de représentativité de 5 % du sujet.

Distributions et valeurs aberrantes.

— Les ratios sont naturellement bornés (tableau 22) :
  — DTI entre 0 et 0,40 ;
  — CUR et ACR entre 0 et 1, à une exception près ;
  — ESR majoritairement entre 0 et 1, avec 57 valeurs plausibles au-delà.

  Les deux méthodes de détection ne signalent aucun outlier pour DTI, CUR et ACR.

— L'IES, produit d'un revenu par une durée, est très asymétrique. Il est plafonné au 99e percentile de l'apprentissage, règle déjà appliquée aux montants : 61 valeurs sont plafonnées dans l'apprentissage, 14 dans le test.

Tableau 22 – Distribution des variables dérivées (apprentissage, IES plafonné).

variable	**n**	**moyenne**	**médiane**	**écart type**	**asymétrie**	**min**	**P99**	**max**
DTI	6 332	0,172	0,167	0,080	0,25	0,000	0,359	0,399
CUR	7 795	0,485	0,497	0,208	-0,23	0,001	0,849	1,016
ACR	7 795	0,515	0,503	0,208	0,23	-0,016	0,976	0,999
ESR	7 518	0,352	0,344	0,238	0,58	0,000	0,975	2,222
IES	6 055	8 314 641,129	6 782 506,000	7 281 864,343	1,39	0,000	37 635 355,040	37 671 224,000

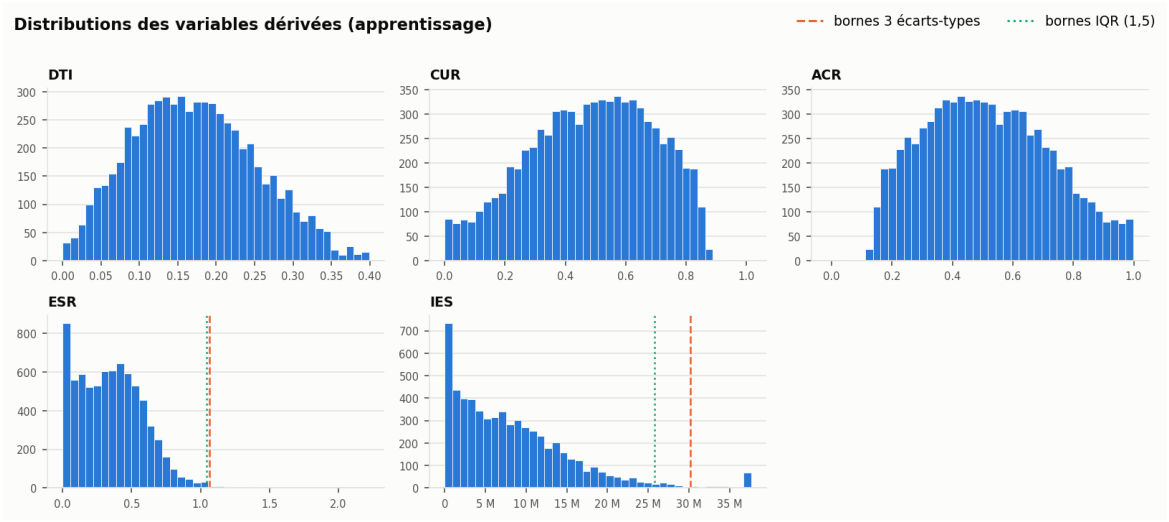


Figure 13 – Distributions des variables dérivées, avec les bornes des deux méthodes de détection (apprentissage).

La figure 13 visualise ces distributions. Celles de DTI, CUR et ACR sont en cloche, comprises entre 0 et 1, et aucune borne de détection ne tombe dans la plage observée. Celle d'ESR présente un pic en 0, correspondant aux anciennetés ń $<$ 1 an ż. Celle de l'IES est très asymétrique, avec un pic en 0 et la masse plafonnée au P99 visible à droite.

4.3 Effet observé sur le défaut

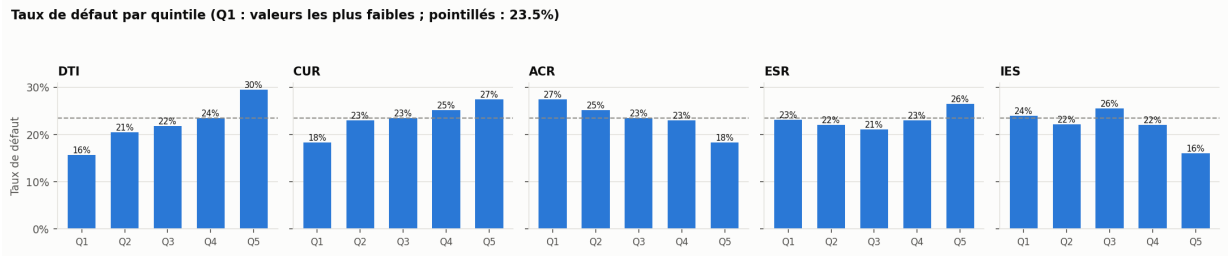


Figure 14 – Taux de défaut par quintile des variables dérivées (apprentissage).

Tableau 23 – Effet attendu et effet observé (premier et dernier quintiles, corrélation de Spearman).

variable	sens attendu	taux défaut 1re classe	taux défaut dernière classe	spearman avec défaut	sens observé	conforme
DTI	+	15,7 %	29,5 %	0,109	+	oui
CUR	+	18,3 %	27,5 %	0,069	+	oui
ACR	–	27,5 %	18,3 %	-0,069	–	oui
ESR	–	23,2 %	26,5 %	0,022	+	non
IES	–	23,9 %	16,0 %	-0,058	–	oui

Le découpage en quintiles est ici descriptif ; la discrétisation retenue pour le modèle sera choisie à l'étape suivante (figure 14, tableau 23).

— **DTI** : effet conforme et monotone. Le taux de défaut passe de 15,7 % à 29,5 % entre le premier et le dernier quintile ; c'est le gradient le plus marqué.

— **CUR** : effet conforme et monotone (18,4 % à 27,5 %). **ACR** en est le miroir exact.

— **IES** : effet conforme, mais concentré sur le dernier quintile (16,0 %, contre 22 à 26 % pour les autres).

— **ESR** : effet *non conforme*. Le dernier quintile est le plus risqué (26,5 %).

Pourquoi l'ESR contredit l'intuition.

— L'ESR suit surtout l'ancienneté d'emploi (Spearman 0,84), qui n'a pas d'effet net sur le défaut : son taux de défaut fluctue entre 22 et 26 % sans tendance.

— Les ESR élevés regroupent en revanche des emprunteurs au court historique de crédit (ancienneté médiane de 14,1 ans contre 18,5 ans). Ce court historique est, lui, un facteur de risque : 25,8 % de défaut dans le premier quintile d'ancienneté de crédit contre 20,5 % dans le dernier.

— Renforcé par la censure à 10 ans, l'ESR mesure donc davantage la jeunesse du dossier de crédit que la stabilité professionnelle.

Il reste candidat, mais son lien avec le défaut est faible (Spearman 0,02) et sera évalué par l'IV et le V de Cramér.

4.4 Redondances

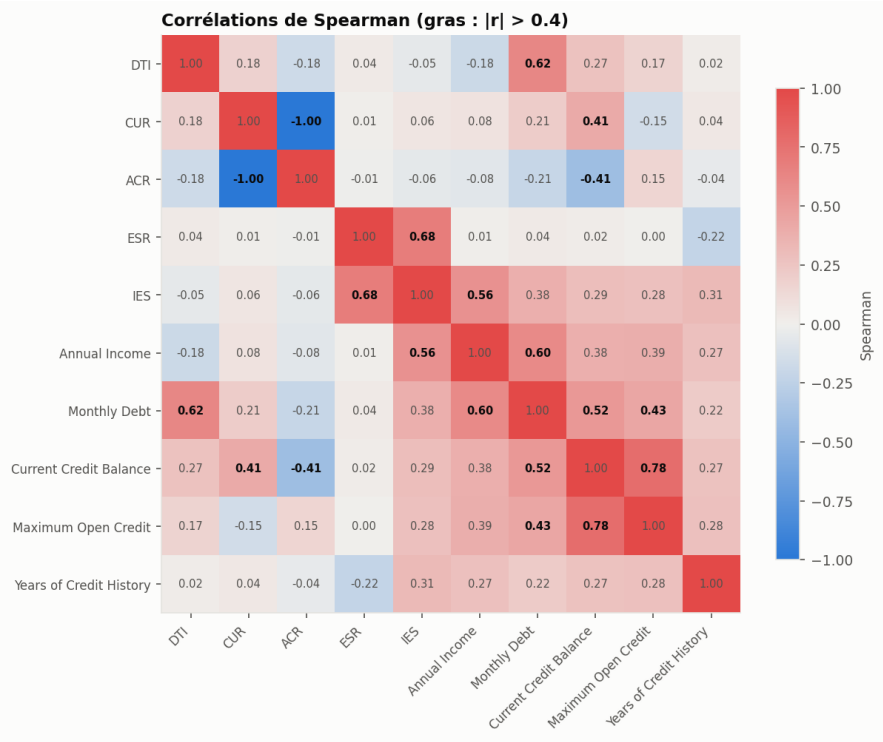


Figure 15 – Corrélations de Spearman entre variables dérivées et variables sources (apprentissage).

Tableau 24 – Paires impliquant une variable dérivée avec $|r| > 0{,}4$.

variable 1	variable 2	spearman
ACR	CUR	-1,00
ESR	IES	0,68
DTI	Monthly Debt	0,62
Annual Income	IES	0,56
CUR	Current Credit Balance	0,41
ACR	Current Credit Balance	-0,41

La figure 15 présente la matrice des corrélations de Spearman entre variables dérivées et variables sources ; les valeurs en gras dépassent 0,4 en valeur absolue. Plusieurs paires dépassent ce seuil du sujet (tableau 24) :

— **CUR et ACR** : $r = -1$. La redondance est parfaite, par construction. Introduire les deux variables rendrait la régression logistique non identifiable : une seule sera conservée.

— **ESR et IES** (0,68) partagent l'ancienneté d'emploi.

— **DTI et Monthly Debt** (0,62), **IES et Annual Income** (0,56).

— **CUR et Current Credit Balance** (0,41).

Ces paires seront arbitrées à l'étape de sélection (sujet 1.3.3), à partir des indicateurs de pouvoir discriminant.

5 Discrétisation, WoE et IV

Sujet 1.2.2 à 1.2.4 et annexe.
Code : `src.binning`, `src.imputation`, `src.pipeline`.
Notebook : partie 4 du notebook `credit_risk.ipynb`.

5.1 Méthode

Formules de l'annexe du sujet. Pour une classe i d'une variable, on note $b_i = \text{Bad}_i/\text{Bad}$ la part des défauts qu'elle contient et $g_i = \text{Good}_i/\text{Good}$ la part des non-défauts. Alors :

$$\text{WoE}_i = \ln \frac{b_i}{g_i}, \qquad \text{IV} = \sum_i (b_i - g_i)\,\text{WoE}_i,$$

$$T = \sqrt{\frac{\chi^2}{n\sqrt{(r-1)(c-1)}}}, \qquad V = \sqrt{\frac{\chi^2}{n\min(r-1, c-1)}},$$

où χ^2 est la statistique du test d'indépendance, n l'effectif, r le nombre de classes et $c = 2$ le nombre de modalités de la cible.

Correction de signe de l'IV. L'énoncé écrit le premier facteur dans l'ordre $g_i - b_i$. Or $g_i - b_i$ et $\ln(b_i/g_i)$ sont toujours de signes opposés : chaque terme de la somme écrite est négatif ou nul, et l'IV de l'énoncé serait toujours ≤ 0. On utilise donc la forme positive, qui en est l'opposé exact. Cette forme est la divergence de Jeffreys entre les distributions des défauts et des non-défauts (annexe A.1) ; elle est nulle si et seulement si la variable ne discrimine pas.

Avec cette convention, un WoE positif signale une classe plus risquée que la moyenne. Une classe sans défaut ou sans non-défaut reçoit une correction de continuité de 0,5 sur ses effectifs.

Pourquoi le T de Tschuprow plutôt que le χ^2 ? Avec une cible binaire ($c = 2$),

$$T = \frac{V}{(r-1)^{1/4}}.$$

À association égale (même V), le T pénalise donc le nombre de classes r. Le χ^2, lui, augmente presque mécaniquement avec r : pour *Credit Score*, il passe de 47 ($k = 2$) à 188 ($k = 9$). Maximiser le T revient à chercher la meilleure association *par degré de liberté* (annexe A.2).

Valeurs manquantes. Une valeur manquante ou non définie forme une classe dédiée, car son absence est informative (section 2.3). Il y a deux exceptions :

— *Current Loan Amount* : ses manquants proviennent de la sentinelle, portée uniquement par des non-défauts. Ils sont remplacés par des montants *tirés au hasard dans la distribution de l'apprentissage* (hot-deck, graine 42). Les prêts concernés se répartissent ainsi dans toutes les classes, proportionnellement à leur taille, sans créer de classe artificiellement sûre (annexe A.5) ;

— *Bankruptcies* : 17 manquants imputés par le mode (0).

Procédure (sujet 1.2.2).

1. Pour $k = 2, \ldots, 10$, les bornes sont les quantiles d'ordre j/k des valeurs renseignées de l'apprentissage.
2. Toute classe doit regrouper au moins 5 % des observations, des défauts et de l'encours (note 2 du sujet ; l'encours est mesuré par le montant du prêt). Une classe trop petite est fusionnée avec sa voisine de taux de défaut le plus proche ; la classe ń manquant ż rejoint la classe de taux le plus proche.
3. On retient le k de T maximal, calculé sur les classes effectivement obtenues après l'étape 2.

Le sujet demande de calculer le T de chaque découpage, de retenir le plus élevé, puis de vérifier la contrainte des 5 %. Calculer le T après regroupement revient à juger chaque découpage sur les classes réellement utilisées. Les deux valeurs, avant et après regroupement, sont rapportées dans le tableau 25.

Tableau 25 – Découpages candidats de *Credit Score* : χ^2, χ^2/n et T avant regroupement, nombre de classes et T après regroupement.

k quantiles	n atomes	chi2	chi2 normalise	tschuprow t	n classes finales	tschuprow t final
2	3	47,3	0,0060	0,0653	3	0,0653
3	4	88,8	0,0113	0,0808	4	0,0808
4	5	124,6	0,0158	0,0890	5	0,0890
5	6	137,5	0,0175	0,0884	6	0,0884
6	7	155,5	0,0198	0,0899	7	0,0899
7	8	162,2	0,0206	0,0883	8	0,0883
8	9	162,1	0,0206	0,0854	8	0,0851
9	10	187,7	0,0239	0,0892	9	0,0887
10	11	166,5	0,0212	0,0818	10	0,0813

Le tableau 25 illustre la procédure sur *Credit Score*. Le χ^2 normalisé augmente globalement avec k, tandis que le T culmine à 0,0899 pour $k = 6$ (7 classes avec la classe ń Manquant ż). Au-delà, l'association gagnée ne compense plus la complexité ajoutée.

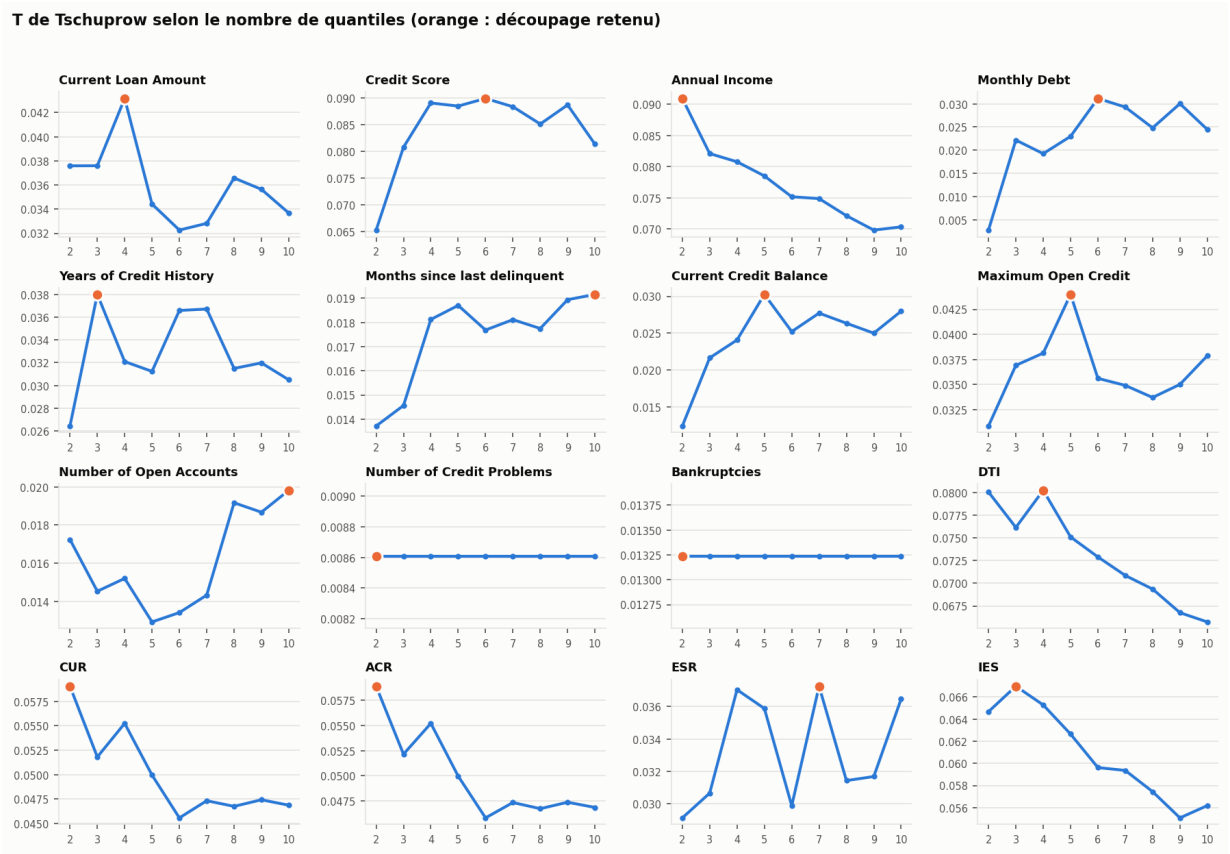


Figure 16 – T de Tschuprow selon le nombre de quantiles, pour chaque variable (en orange : le découpage retenu).

La figure 16 généralise cette lecture aux 16 variables quantitatives.

— *Annual Income*, *DTI*, CUR et *IES* atteignent leur maximum pour un petit k (2 à 4) : quelques coupures captent l'essentiel du signal.

— Les variables au lien diffus, comme *Months since last delinquent* ou *Number of Open Accounts*, ont des courbes basses et irrégulières, et le maximum y est atteint pour $k = 10$.

— Pour les deux comptages, la courbe est plate : tous les k donnent la même coupure ń 0 ż / ń au moins 1 ż.

5.2 Découpages retenus

Tableau 26 – Découpage retenu pour chaque variable quantitative : nombre de quantiles, nombre de classes, χ^2 normalisé, T et parts minimales.

variable	k retenu	n classes	chi2 normalise	tschuprow t	part min obs	part min défauts
Current Loan Amount	4	4	0,0032	0,0432	25,0 %	20,7 %
Credit Score	6	7	0,0198	0,0899	12,6 %	6,5 %
Annual Income	2	3	0,0117	0,0909	19,5 %	23,7 %
Monthly Debt	6	6	0,0022	0,0312	16,7 %	14,6 %
Years of Credit History	3	3	0,0020	0,0380	33,0 %	29,2 %
Months since last delinquent	10	7	0,0012	0,0192	5,0 %	5,1 %
Current Credit Balance	5	5	0,0018	0,0303	20,0 %	17,7 %
Maximum Open Credit	5	5	0,0039	0,0440	20,0 %	15,7 %
Number of Open Accounts	10	10	0,0012	0,0198	6,4 %	5,5 %
Number of Credit Problems	2	2	0,0001	0,0086	14,5 %	13,9 %
Bankruptcies	2	2	0,0002	0,0132	11,3 %	10,5 %
DTI	4	5	0,0129	0,0802	19,5 %	13,9 %
CUR	2	2	0,0035	0,0591	49,6 %	45,1 %
ACR	2	2	0,0035	0,0589	49,6 %	45,1 %
ESR	7	7	0,0036	0,0373	13,7 %	12,0 %
IES	3	4	0,0078	0,0670	23,0 %	19,7 %

Le tableau 26 récapitule les choix. Le nombre de classes va de 2 à 10. La contrainte des 5 % est partout respectée : au minimum 5,0 % des observations et 5,1 % des défauts, pour *Months since last delinquent*.

5.3 Variables à nombreuses modalités et regroupement des qualitatives (sujets 1.2.3, 1.2.4)

Toutes les variables quantitatives ont plus de 10 valeurs distinctes, sauf les deux comptages d'incidents : elles ne peuvent entrer telles quelles dans une grille de score, d'où leur discrétisation. *Purpose* (12 modalités) et *Years in current job* (11 modalités et `n/a`) dépassent 4 modalités.

Le regroupement des variables qualitatives procède en trois temps :

1. les modalités sont ordonnées, par taux de défaut pour une variable nominale, dans l'ordre naturel pour une variable ordinale ;
2. les modalités trop petites (seuil de 5 %) sont fusionnées ;
3. les classes voisines dont les taux de défaut ne diffèrent pas significativement (χ^2 2×2 au seuil de 5 %) sont fusionnées, la paire la moins significative d'abord.

Tableau 27 – Classes finales des variables qualitatives : effectif, part des observations et des défauts, taux de défaut et WoE (apprentissage).

variable	classe	n	part	part défauts	taux défaut	woe
Term	Short Term	5 647	71,8 %	62,0 %	20,2 %	-0,189
Term	Long Term	2 214	28,2 %	38,0 %	31,7 %	0,415
Home Ownership	Home Mortgage	3 847	48,9 %	43,7 %	21,0 %	-0,144
Home Ownership	Own Home + Rent	4 014	51,1 %	56,3 %	25,9 %	0,129
Purpose	Buy a Car + Wedding + Major Purchase + Medical Bills + Home Improvements + Other	1 379	17,5 %	15,9 %	21,2 %	-0,128
Purpose	Take a Trip + Debt Consolidation + Buy House + Business Loan + Moving + Educational Expenses	6 482	82,5 %	84,1 %	23,9 %	0,026
Years in current job	< 1 year + 1 year + 2 years + 3 years + 4 years + 5 years + 6 years + 7 years + 8 years	4 748	60,4 %	59,8 %	23,3 %	-0,012
Years in current job	9 years + Non renseigné	663	8,4 %	10,0 %	27,9 %	0,233
Years in current job	10+ years	2 450	31,2 %	30,1 %	22,7 %	-0,044

Le tableau 27 présente les classes obtenues.

— **Purpose.** Avant regroupement, les taux de défaut des modalités vont de 15,3 % à 45,5 %, mais plusieurs modalités ont de très petits effectifs (11 prêts pour *Educational Expenses*, 6 pour *Wedding*). Il reste deux classes :

  — les motifs de consommation planifiée, 21,2 % de défaut ;

  — les autres, 23,9 %.

  La différence est significative ($p = 0{,}032$). L'IV passe de 0,0086 à 0,0033 : la perte vient des WoE extrêmes, mais peu fiables, des modalités minuscules.

— **Years in current job.** Aucune progression du risque avec l'ancienneté. La modalité `n/a` (30,0 % de défaut, 4,4 % des prêts, sous le seuil) rejoint *9 years*, de taux le plus proche. Ce regroupement n'a pas de sens économique propre. Les trois classes obtenues diffèrent significativement entre voisines ($p = 0{,}008$ et $p = 0{,}005$).

— **Home Ownership.** *Own Home* et *Rent* sont regroupées (25,9 % de défaut) face à *Home Mortgage* (21,0 %).

— **Term.** Les deux modalités sont conservées (tableau 31).

5.4 WoE et IV

Tableau 28 – IV, interprétation (table 3 de l'annexe), T de Tschuprow et V de Cramér des 20 variables candidates (apprentissage).

variable	n classes	iv	pouvoir	tschuprow t	cramer v
Credit Score	7	0,1210	moyen	0,0899	0,1407
Term	2	0,0780	faible	0,1217	0,1217
DTI	5	0,0740	faible	0,0802	0,1135
Annual Income	3	0,0673	faible	0,0909	0,1081
IES	4	0,0443	faible	0,0670	0,0881
Maximum Open Credit	5	0,0228	faible	0,0440	0,0622
CUR	2	0,0195	non prédictive	0,0591	0,0591
ACR	2	0,0194	non prédictive	0,0589	0,0589
Current Loan Amount	4	0,0188	non prédictive	0,0432	0,0568
ESR	7	0,0187	non prédictive	0,0373	0,0583
Home Ownership	2	0,0185	non prédictive	0,0576	0,0576
Monthly Debt	6	0,0123	non prédictive	0,0312	0,0466
Years of Credit History	3	0,0116	non prédictive	0,0380	0,0452
Current Credit Balance	5	0,0103	non prédictive	0,0303	0,0428
Number of Open Accounts	10	0,0066	non prédictive	0,0198	0,0343
Years in current job	3	0,0055	non prédictive	0,0272	0,0323
Months since last delinquent	7	0,0051	non prédictive	0,0192	0,0300
Purpose	2	0,0033	non prédictive	0,0242	0,0242
Bankruptcies	2	0,0010	non prédictive	0,0132	0,0132
Number of Credit Problems	2	0,0004	non prédictive	0,0086	0,0086

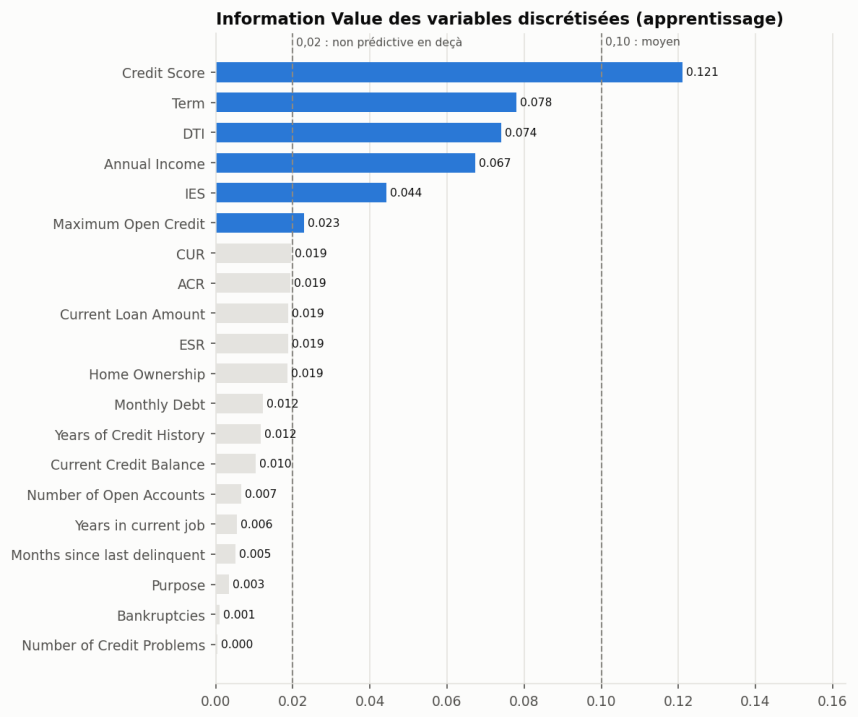


Figure 17 – IV des variables discrétisées. Pointillés : seuils de 0,02 (non prédictive en deçà) et de 0,10 (pouvoir moyen).

Le tableau 28 et la figure 17 classent les variables par pouvoir discriminant.

- **Pouvoir moyen** ($0{,}10 \leq \text{IV} < 0{,}30$) : *Credit Score* seul (0,121).
- **Pouvoir faible** ($0{,}02 \leq \text{IV} < 0{,}10$) : *Term* (0,078), *DTI* (0,074), *Annual Income* (0,067), *IES* (0,044) et *Maximum Open Credit* (0,023).
- **IV inférieur à 0,02** : les 14 autres variables. Quatre sont juste sous le seuil : CUR (0,0195), ACR (0,0194), *Current Loan Amount* (0,0188) et ESR (0,0187).

Aucune variable n'atteint 0,5 : il n'y a pas de soupçon de fuite d'information, ce qui confirme que les artefacts de la section 2 ont bien été neutralisés.

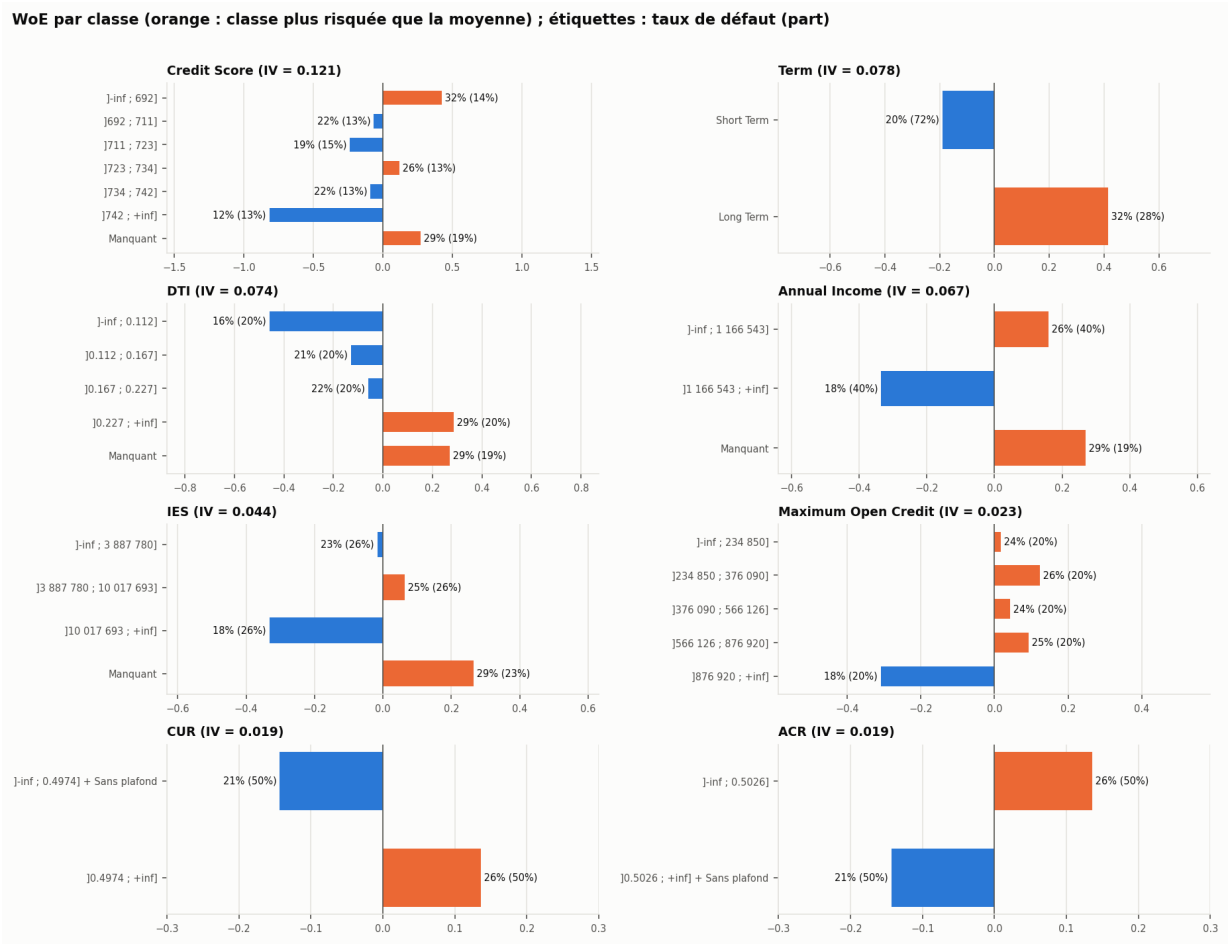


Figure 18 – WoE par classe des huit variables de plus fort IV (orange : classe plus risquée que la moyenne). Étiquettes : taux de défaut et part de la classe.

La figure 18 montre que les WoE suivent les effets économiques attendus :

— un score bas, un prêt long, un DTI élevé ou un revenu faible correspondent à un WoE positif ;

— un plafond de crédit élevé correspond à un WoE négatif.

La classe ń Manquant ż de *Credit Score*, *Annual Income* et *DTI* a le même WoE (+0,27), puisqu'elle regroupe les mêmes 1 529 prêts.

Tableau 29 – WoE et contribution à l'IV par classe de *Credit Score*.

classe	n	part	taux défaut	woe	iv classe
]-inf ; 692]	1 085	13,8 %	31,9 %	0,423	0,0274
]692 ; 711]	1 032	13,1 %	22,3 %	-0,067	0,0006
]711 ; 723]	1 166	14,8 %	19,5 %	-0,238	0,0079
]723 ; 734]	991	12,6 %	25,6 %	0,117	0,0018
]734 ; 742]	1 052	13,4 %	21,9 %	-0,092	0,0011
]742 ; +inf]	1 006	12,8 %	11,9 %	-0,817	0,0672
Manquant	1 529	19,5 %	28,6 %	0,269	0,0151

Le tableau 29 détaille *Credit Score*. Le taux de défaut va de 31,9 % (score ≤ 692, WoE +0,42) à 11,9 % (score > 742, WoE −0,82). Cette dernière classe apporte à elle seule 0,067 des 0,121 d'IV : l'essentiel du pouvoir discriminant du score vient de l'identification des très bons scores.

La relation n'est pas monotone : la classe]723 ; 734] est un peu plus risquée que ses voisines.

Le sujet n'impose pas la monotonie, et cette irrégularité de faible amplitude relève du bruit d'échantillonnage.

Tableau 30 – WoE et contribution à l'IV par classe de DTI.

classe	n	part	taux défaut	woe	iv classe
]-inf ; 0.112]	1 583	20,1 %	16,2 %	-0,459	0,0372
]0.112 ; 0.167]	1 583	20,1 %	21,2 %	-0,129	0,0033
]0.167 ; 0.227]	1 583	20,1 %	22,4 %	-0,059	0,0007
]0.227 ; +inf]	1 583	20,1 %	29,0 %	0,286	0,0177
Manquant	1 529	19,5 %	28,6 %	0,269	0,0151

Pour le DTI (tableau 30), la relation est monotone : le taux de défaut passe de 16,2 % (DTI $\leq 0{,}112$, WoE $-0{,}46$) à 29,0 % (DTI $> 0{,}227$, WoE $+0{,}29$). La classe ń Manquant ż (28,7 %) est proche de la classe la plus risquée.

Tableau 31 – WoE et contribution à l'IV de *Term*.

classe	n	part	taux défaut	woe	iv classe
Short Term	5 647	71,8 %	20,2 %	-0,189	0,0245
Long Term	2 214	28,2 %	31,7 %	0,415	0,0536

Pour *Term* (tableau 31), les prêts longs (28,2 % des prêts) ont un taux de défaut de 31,7 % (WoE $+0{,}41$), contre 20,2 % pour les prêts courts (WoE $-0{,}19$).

Lien entre WoE et régression logistique. D'après la formule de Bayes, la cote de défaut d'une classe i s'écrit

$$\ln \frac{P(D=1 \mid i)}{P(D=0 \mid i)} = \ln \frac{\text{Bad}}{\text{Good}} + \text{WoE}_i.$$

Le WoE est donc exactement la contribution de la classe à la log-cote, ce qui justifie son usage comme codage des variables dans la régression logistique (annexe A.6).

Application au test. Les règles apprises (bornes, regroupements, WoE) sont appliquées telles quelles au test : toutes les observations reçoivent une classe, et la part d'une classe ne diffère jamais de plus de 2,7 points entre apprentissage et test.

6 Sélection des variables candidates

Sujet 1.3.
Code : `src.selection`.
Notebook : partie 5 du notebook `credit_risk.ipynb`.

6.1 Stabilité : quatre échantillons bootstrap (sujet 1.3.1)

Quatre échantillons de 7 861 prêts sont tirés avec remise dans l'apprentissage. Dans chacun, on calcule, pour chaque variable et avec les classes de la section 5, la part de chaque classe, son taux de défaut, son WoE et l'IV de la variable.

PSI et correction de signe. L'énoncé définit le PSI par $\sum_i (P_i - Q_i)\ln(Q_i/P_i)$. Chaque terme de cette somme est négatif ou nul, ce qui contredit les seuils d'interprétation (0,10 et 0,25). On utilise donc la forme positive $\text{PSI} = \sum_i (Q_i - P_i)\ln(Q_i/P_i)$, symétrique en P et Q. C'est la somme

des deux divergences de Kullback-Leibler $\mathrm{KL}(Q\|P) + \mathrm{KL}(P\|Q)$ (annexe A.1). Une classe vide reçoit une proportion plancher de 10^{-4}.

Tableau 32 – Matrice des PSI entre les quatre échantillons bootstrap (table 2 du sujet).

variable	1 vs 2	1 vs 3	1 vs 4	2 vs 3	2 vs 4	3 vs 4
Credit Score	0,0005	0,0022	0,0023	0,0029	0,0025	0,0018
Term	0,0001	0,0003	0,0012	0,0000	0,0006	0,0003
DTI	0,0004	0,0005	0,0001	0,0009	0,0003	0,0007
Annual Income	0,0003	0,0004	0,0001	0,0006	0,0001	0,0006
IES	0,0005	0,0009	0,0001	0,0016	0,0011	0,0008
Maximum Open Credit	0,0018	0,0002	0,0002	0,0013	0,0014	0,0001
CUR	0,0001	0,0000	0,0000	0,0002	0,0001	0,0000
ACR	0,0001	0,0000	0,0000	0,0002	0,0001	0,0000
Current Loan Amount	0,0000	0,0002	0,0002	0,0004	0,0003	0,0004
ESR	0,0002	0,0017	0,0004	0,0019	0,0007	0,0024
Home Ownership	0,0006	0,0004	0,0000	0,0021	0,0010	0,0002
Monthly Debt	0,0011	0,0013	0,0004	0,0012	0,0014	0,0022
Years of Credit History	0,0003	0,0000	0,0001	0,0005	0,0007	0,0001
Current Credit Balance	0,0007	0,0022	0,0005	0,0040	0,0006	0,0016
Number of Open Accounts	0,0024	0,0023	0,0028	0,0029	0,0017	0,0027
Years in current job	0,0001	0,0000	0,0001	0,0002	0,0001	0,0001
Months since last delinquent	0,0004	0,0025	0,0008	0,0022	0,0009	0,0030
Purpose	0,0010	0,0000	0,0000	0,0009	0,0006	0,0000
Bankruptcies	0,0003	0,0000	0,0002	0,0003	0,0011	0,0002
Number of Credit Problems	0,0002	0,0002	0,0001	0,0008	0,0007	0,0000



Figure 19 – Carte de chaleur des PSI entre échantillons bootstrap (échelle de 0 à 0,01, soit dix fois moins que le seuil de vigilance).

Stabilité des effectifs. Toutes les variables sont stables : le PSI maximal vaut 0,0040, 25 fois moins que le seuil de vigilance (tableau 32). La figure 19, dont l'échelle s'arrête à 0,01, le confirme visuellement : aucune case n'approche cette valeur. Les échantillons provenant de la même population, le PSI ne mesure ici que la fluctuation d'échantillonnage. Il ne renseigne pas sur la stabilité du lien avec le défaut, qu'on examine avec d'autres indicateurs (tableau 33).

Tableau 33 – Stabilité du lien avec le défaut sur les quatre échantillons : IV (moyenne, écart-type, coefficient de variation), classes dont le WoE change de signe, concordance minimale de l'ordre des classes.

variable	iv moyen	iv ecart type	iv cv	classes woe signe instable	concordance rangs min
Credit Score	0,1359	0,0229	0,17	0	0,96
Term	0,0784	0,0063	0,08	0	1,00
DTI	0,0806	0,0151	0,19	1	0,90
Annual Income	0,0753	0,0088	0,12	0	1,00
IES	0,0456	0,0136	0,30	2	1,00
Maximum Open Credit	0,0264	0,0084	0,32	0	0,30
CUR	0,0230	0,0067	0,29	0	1,00
ACR	0,0229	0,0067	0,29	0	1,00
Current Loan Amount	0,0187	0,0097	0,52	1	0,20
ESR	0,0237	0,0064	0,27	1	0,83
Home Ownership	0,0213	0,0024	0,12	0	1,00
Monthly Debt	0,0124	0,0059	0,48	3	0,60
Years of Credit History	0,0114	0,0019	0,17	0	0,50
Current Credit Balance	0,0108	0,0043	0,39	2	0,90
Number of Open Accounts	0,0127	0,0059	0,47	7	0,55
Years in current job	0,0058	0,0012	0,21	0	0,50
Months since last delinquent	0,0088	0,0032	0,37	4	0,36
Purpose	0,0057	0,0053	0,93	0	1,00
Bankruptcies	0,0012	0,0015	1,23	2	-1,00
Number of Credit Problems	0,0002	0,0003	1,13	2	-1,00

Stabilité du lien avec le défaut.

- **Variables stables.** *Credit Score*, *Term*, *Annual Income*, *Home Ownership* et CUR gardent le même ordre des classes dans tous les échantillons (concordance $\geq 0{,}96$).
- **Variables à forte variabilité.** Ce sont toutes des variables d'IV inférieur à 0,02 :
  - *Purpose* : coefficient de variation de l'IV de 0,93 ;
  - les comptages d'incidents : ordre des classes inversé d'un échantillon à l'autre ;
  - *Number of Open Accounts* : 7 classes dont le WoE change de signe.
- **Seuils optimaux.** Le nombre de quantiles retenu est stable pour *Annual Income* et les comptages. Il varie pour les autres variables, car leurs courbes de T en fonction de k sont plates ; l'IV, lui, reste stable.

6.2 Pouvoir discriminant : V de Cramér et IV (sujet 1.3.2)

Tableau 34 – V de Cramér avec la cible, IV, p-value du χ^2 et rangs.

variable	cramer v	iv	p-value Khiš	rang v	rang iv
Credit Score	0,1407	0,1210	< 0,001	1	1
Term	0,1217	0,0780	< 0,001	2	2
DTI	0,1135	0,0740	< 0,001	3	3
Annual Income	0,1081	0,0673	< 0,001	4	4
IES	0,0881	0,0443	< 0,001	5	5
Maximum Open Credit	0,0622	0,0228	< 0,001	6	6
CUR	0,0591	0,0195	< 0,001	7	7
ACR	0,0589	0,0194	< 0,001	8	8
Current Loan Amount	0,0568	0,0188	< 0,001	11	9
ESR	0,0583	0,0187	< 0,001	9	10
Home Ownership	0,0576	0,0185	< 0,001	10	11
Monthly Debt	0,0466	0,0123	0,004	12	12
Years of Credit History	0,0452	0,0116	< 0,001	13	13
Current Credit Balance	0,0428	0,0103	0,006	14	14
Number of Open Accounts	0,0343	0,0066	0,413	15	15
Years in current job	0,0323	0,0055	0,017	16	16
Months since last delinquent	0,0300	0,0051	0,314	17	17
Purpose	0,0242	0,0033	0,032	18	18
Bankruptcies	0,0132	0,0010	0,241	19	19
Number of Credit Problems	0,0086	0,0004	0,445	20	20

Le tableau 34 donne, pour chaque variable, le V de Cramér avec la cible, l'IV, la p-value du χ^2 et les rangs selon les deux mesures.

— **Concordance des deux mesures.** Le V de Cramér et l'IV classent les variables presque à l'identique (corrélation de Spearman des rangs : 0,995). Les deux mesures quantifient l'écart entre la distribution des défauts et celle des non-défauts dans les classes.

— **Complémentarité.** L'IV dispose d'une échelle d'interprétation métier, tandis que le V provient d'un test statistique.

— **Usage dans la sélection.** Parmi les variables d'IV inférieur à 0,02, dix ont une association significative avec le défaut ($p < 0,05$) et quatre n'en ont pas. Les premières portent un signal faible mais réel ; les secondes sont exclues.

— **Pourquoi ne pas exclure toutes les variables d'IV < 0,02.** L'IV est une mesure univariée : exclure CUR (IV 0,0195) au seuil de 0,02 serait arbitraire. Ces candidates ń faibles ż sont donc soumises à la sélection pas à pas.

6.3 Corrélations (sujet 1.3.3)

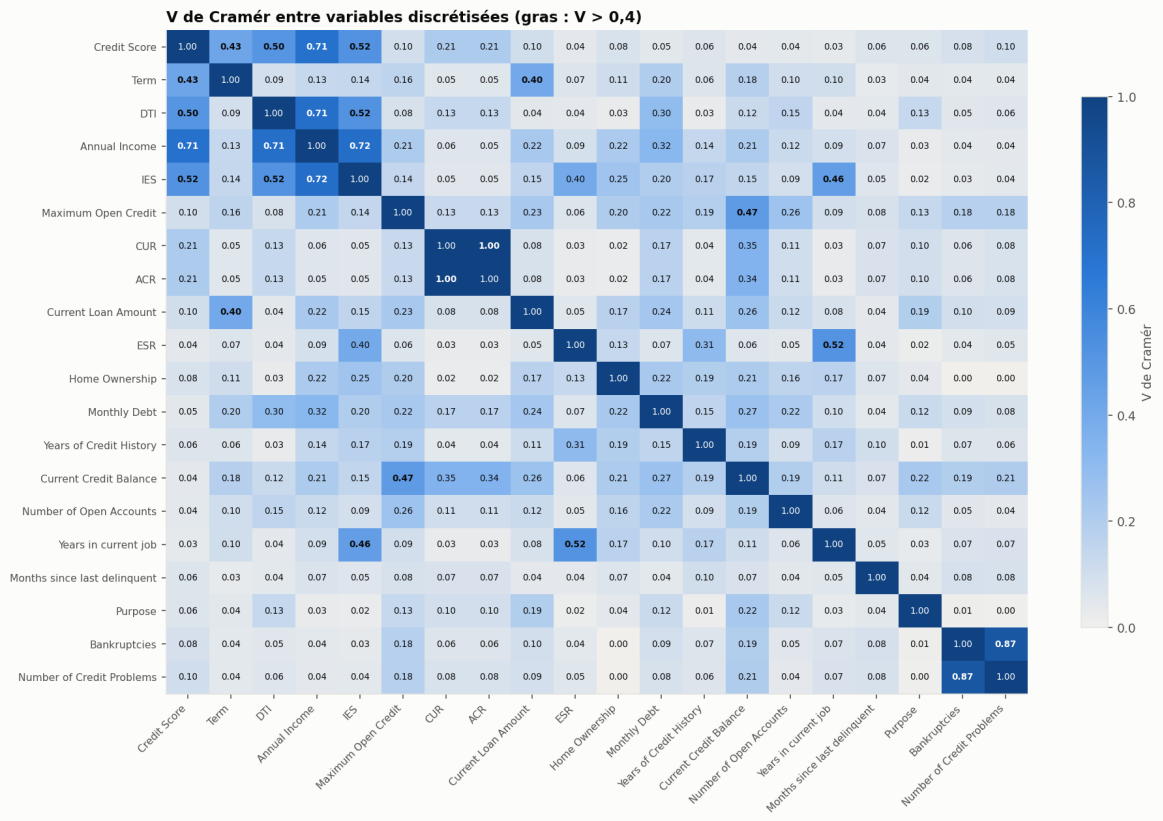


Figure 20 – V de Cramér entre variables discrétisées.

Tableau 35 – Paires avec V > 0,4 : V hors classes ń manquant ż, corrélation des variables codées en WoE et décision.

variable 1	variable 2	cramer v	cramer v hors manquants	correlation woe	redondante	a exclure
Current Loan Amount	Term	0,401	0,401	0,310	non	
Credit Score	Annual Income	0,710	0,091	0,244	non	
Credit Score	DTI	0,505	0,079	0,291	non	
Credit Score	IES	0,520	0,023	0,264	non	
Credit Score	Term	0,425	0,464	0,285	non	
Annual Income	DTI	0,715	0,149	0,376	non	
Annual Income	IES	0,725	0,501	0,645	oui	IES
Current Credit Balance	Maximum Open Credit	0,473	0,473	0,171	non	
Number of Credit Problems	Bankruptcies	0,866	0,866	0,866	oui	Number of Credit Problems
DTI	IES	0,521	0,054	0,371	non	
CUR	ACR	1,000		1,000	oui	ACR
ESR	Years in current job	0,518	0,600	0,261	non	
IES	Years in current job	0,461	0,670	0,227	non	

La figure 20 présente la matrice des V de Cramér entre les 20 variables discrétisées ; les valeurs supérieures à 0,4 sont en gras. Les groupes de variables associées sont définis par V > 0,4, comme le demande le sujet. Au sein de chaque groupe, on compare deux coefficients :

— **la corrélation des variables codées en WoE**, telles qu'elles entrent dans la régression, qui mesure la multicolinéarité ;

— **le V hors classes ń manquant ż**, qui indique si l'association ne vient que d'un motif de valeurs manquantes partagé.

Une paire est jugée redondante si $|\rho_{\text{WoE}}| > 0{,}4$. La variable d'IV le plus faible est alors exclue. Le tableau 35 donne ces trois mesures pour les 13 paires de V supérieur à 0,4.

Une règle ń une seule variable par groupe de V > 0,4 ż, appliquée à la lettre, aurait exclu *Term* (V = 0,43 avec *Credit Score*). Le sujet demande toutefois de ń comparer les coefficients de

corrélation ż au sein de chaque groupe. Le critère de corrélation des WoE répond à cette consigne et cible le seul effet nuisible à la régression, la multicolinéarité.

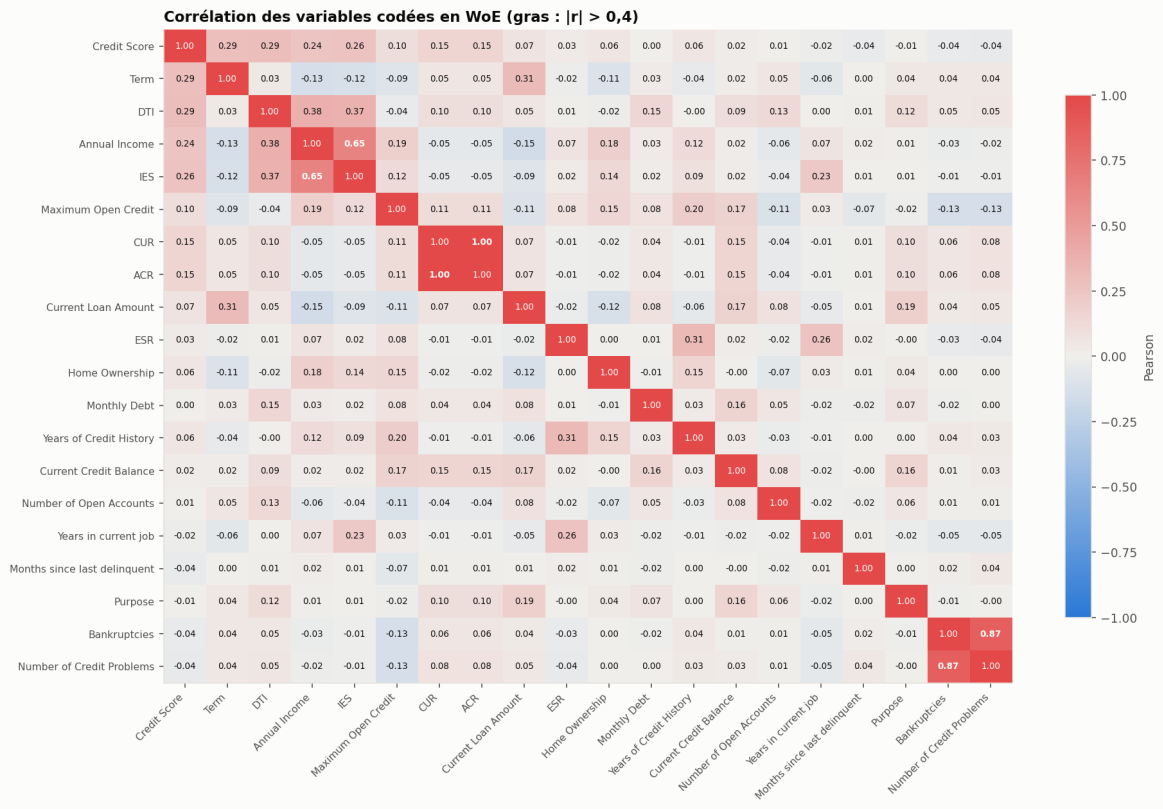


Figure 21 – Corrélations (Pearson) des variables codées en WoE ; en gras : $|r| > 0{,}4$.

La figure 21 montre que, hors des paires CUR/ACR, *Annual Income*/IES et des deux comptages d'incidents, toutes les corrélations entre WoE restent inférieures à 0,4.

Lecture des paires.

- **Motif de manquants partagé.** *Credit Score*, *Annual Income*, *DTI* et *IES* ont des V de 0,50 à 0,72. Ce lien vient de leur classe ń Manquant ż commune (1 529 prêts). Hors de ces classes, le V tombe à 0,02–0,15, sauf entre *Annual Income* et *IES*.
- **Credit Score et Term.** Leur association est réelle (V 0,43), mais leurs WoE ne sont corrélés qu'à 0,29. Les deux variables sont conservées, et l'absence de multicolinéarité est vérifiée par le VIF (section 7).
- **Paires redondantes.** Trois paires sont redondantes :
  - CUR et ACR (corrélation 1, ACR = 1 − CUR) : ACR est exclue ;
  - *Annual Income* et IES (0,65) : IES est exclue ;
  - les deux comptages d'incidents (0,87), déjà exclus pour absence de pouvoir discriminant.

6.4 Jeu final

Tableau 36 – Décision et justification pour chacune des 20 variables.

variable	iv	p-value Khiš	psi max	decision	justification
Credit Score	0,1210	< 0,001	0,0029	candidate	IV ≥ 0,02, stable, non redondante
Term	0,0780	< 0,001	0,0012	candidate	IV ≥ 0,02, stable, non redondante
DTI	0,0740	< 0,001	0,0009	candidate	IV ≥ 0,02, stable, non redondante
Annual Income	0,0673	< 0,001	0,0006	candidate	IV ≥ 0,02, stable, non redondante
IES	0,0443	< 0,001	0,0016	exclue	redondante avec Annual Income (IV plus élevé)
Maximum Open Credit	0,0228	< 0,001	0,0018	candidate	IV ≥ 0,02, stable, non redondante
CUR	0,0195	< 0,001	0,0002	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
ACR	0,0194	< 0,001	0,0002	exclue	redondante avec CUR (IV plus élevé)
Current Loan Amount	0,0188	< 0,001	0,0004	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
ESR	0,0187	< 0,001	0,0024	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Home Ownership	0,0185	< 0,001	0,0021	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Monthly Debt	0,0123	0,004	0,0022	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Years of Credit History	0,0116	< 0,001	0,0007	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Current Credit Balance	0,0103	0,006	0,0040	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Number of Open Accounts	0,0066	0,413	0,0029	exclue	IV < 0,02 et Khiš non significatif (p = 0,41) : non prédictive
Years in current job	0,0055	0,017	0,0002	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Months since last delinquent	0,0051	0,314	0,0030	exclue	IV < 0,02 et Khiš non significatif (p = 0,31) : non prédictive
Purpose	0,0033	0,032	0,0010	candidate (faible)	IV < 0,02 mais association significative : arbitrée par le stepwise
Bankruptcies	0,0010	0,241	0,0011	exclue	IV < 0,02 et Khiš non significatif (p = 0,24) : non prédictive
Number of Credit Problems	0,0004	0,445	0,0008	exclue	IV < 0,02 et Khiš non significatif (p = 0,45) : non prédictive

14 variables candidates sont retenues (tableau 36) :

— **5 variables d'IV** ≥ 0,02 : *Credit Score*, *Term*, *DTI*, *Annual Income*, *Maximum Open Credit* ;

— **9 candidates ń faibles ż**, d'IV < 0,02 mais d'association significative.

Six variables sont exclues : 2 pour redondance (ACR, IES) et 4 pour absence de pouvoir discriminant. Aucune n'est exclue pour instabilité.

7 Régression logistique et sélection pas à pas

Sujet 1.4.

Code : `src.modeling`, `src.sampling`.

Notebook : partie 6 du notebook `credit_risk.ipynb`.

7.1 Représentativité des échantillons (sujet 1.4.1)

Le découpage 80/20, stratifié sur la cible avec `random_state = 42`, a été réalisé dès la fin du contrôle qualité (tableau 9). Sa représentativité se vérifie sur trois plans :

— **Taux de défaut.** 23,47 % en apprentissage, 23,50 % en test, 23,48 % dans la population.

— **Variables brutes.** Les médianes sont presque identiques : 723 pour *Credit Score* dans les trois échantillons, 17,0 et 16,9 ans d'historique de crédit.

— **Variables discrétisées.** Le PSI entre apprentissage et test est inférieur à 0,01 pour les 20 variables, et aucun test d'homogénéité du χ^2 n'est significatif à 5 % (tableau 37).

Les deux échantillons sont donc représentatifs : les écarts de performance entre apprentissage et test relèveront du sur-ajustement ou de la variance d'échantillonnage, non d'une différence de population.

Tableau 37 – PSI apprentissage/test et test d'homogénéité du χ^2 par variable.

variable	psi	stabilite	p-value homogeneite
Number of Open Accounts	0,0063	stable	0,366
Monthly Debt	0,0039	stable	0,295
Credit Score	0,0039	stable	0,398
Current Credit Balance	0,0036	stable	0,218
Years of Credit History	0,0033	stable	0,072
IES	0,0030	stable	0,200
DTI	0,0026	stable	0,388
ESR	0,0024	stable	0,707
Maximum Open Credit	0,0021	stable	0,496
Months since last delinquent	0,0018	stable	0,835
CUR	0,0013	stable	0,154
ACR	0,0013	stable	0,156
Term	0,0012	stable	0,167
Current Loan Amount	0,0009	stable	0,685
Home Ownership	0,0006	stable	0,330
Annual Income	0,0004	stable	0,708
Number of Credit Problems	0,0004	stable	0,433
Years in current job	0,0002	stable	0,834
Purpose	0,0000	stable	0,837
Bankruptcies	0,0000	stable	0,878

7.2 Spécification

Chaque variable entre dans le modèle par le WoE de sa classe :

$$\ln \frac{P(D=1 \mid X)}{P(D=0 \mid X)} = \beta_0 + \sum_j \beta_j \, \mathrm{WoE}_j(X_j).$$

Les coefficients sont estimés par maximum de vraisemblance. La log-vraisemblance s'écrit

$$\ell(\beta) = \sum_{i=1}^{n} \left[y_i \ln p_i + (1-y_i) \ln(1-p_i) \right], \qquad p_i = \frac{1}{1+e^{-x_i^\top \beta}},$$

et elle est maximisée numériquement (Newton-Raphson).

Un WoE positif signale une classe risquée, donc **le signe attendu de chaque coefficient est positif**. Si une variable était seule dans le modèle, son coefficient vaudrait exactement 1 (annexe A.6). Un coefficient compris entre 0 et 1 indique qu'une partie de son effet est déjà portée par d'autres variables.

Le rapport de cotes (odds ratio) e^{β_j} mesure la multiplication de la cote de défaut pour une hausse d'une unité de WoE. Le passage d'une classe a à une classe b multiplie la cote par $\exp\{\beta_j(\mathrm{WoE}_b - \mathrm{WoE}_a)\}$.

Les indicateurs sont les suivants.

— AIC $= -2\ln L + 2k$ et BIC $= -2\ln L + k \ln n$, où k est le nombre de paramètres. Avec $n = 7\,861$, la pénalité du BIC vaut $\ln n \approx 8{,}97$ par paramètre, contre 2 pour l'AIC.

— L'AUC est la probabilité qu'un défaut tiré au hasard reçoive une PD plus élevée qu'un non-défaut tiré au hasard.

— $\mathrm{AR} = 2\,\mathrm{AUC} - 1$ est le coefficient de Gini (annexe A.8).

La matrice de confusion utilise un seuil égal au taux de défaut de l'apprentissage (23,47 %).

7.3 Modèle avec toutes les candidates (sujet 1.4.2)

Tableau 38 – Modèle logistique sur les 14 variables candidates (apprentissage).

variable	coefficient	ecart type	z	p-value	odds ratio	or ic bas	or ic haut
const	-1,183	0,028	-42,83	< 0,001	0,306	0,290	0,323
Credit Score	0,477	0,092	5,20	< 0,001	1,611	1,346	1,928
Term	0,934	0,108	8,68	< 0,001	2,545	2,061	3,142
DTI	0,534	0,117	4,56	< 0,001	1,705	1,356	2,145
Annual Income	0,646	0,124	5,21	< 0,001	1,908	1,496	2,433
Maximum Open Credit	0,658	0,200	3,30	< 0,001	1,932	1,306	2,857
CUR	0,636	0,203	3,13	0,002	1,888	1,269	2,810
Current Loan Amount	0,584	0,224	2,61	0,009	1,793	1,156	2,780
ESR	0,733	0,218	3,36	< 0,001	2,082	1,357	3,193
Home Ownership	0,957	0,209	4,57	< 0,001	2,605	1,728	3,925
Monthly Debt	0,510	0,256	1,99	0,046	1,665	1,008	2,750
Years of Credit History	0,302	0,278	1,09	0,277	1,353	0,784	2,334
Current Credit Balance	0,249	0,287	0,87	0,387	1,282	0,730	2,253
Years in current job	0,838	0,376	2,23	0,026	2,312	1,106	4,834
Purpose	-0,085	0,496	-0,17	0,864	0,919	0,347	2,428

Le modèle complet a les caractéristiques suivantes (tableau 38) :

— **Qualité d'ajustement.** Log-vraisemblance −4 078,5, AIC 8 187,0, BIC 8 291,6, AUC 0,649, AR 0,298.

— **Signes.** 13 coefficients sur 14 sont positifs.

— **Variables problématiques.** Trois variables ne sont pas significatives : *Purpose* (coefficient négatif, $p = 0{,}86$), *Current Credit Balance* ($p = 0{,}39$) et *Years of Credit History* ($p = 0{,}28$).

— **Multicolinéarité.** Elle est faible : tous les VIF sont inférieurs à 1,4.

— **Test.** L'AUC vaut 0,626 et l'AR 0,253.

Ce modèle n'est pas satisfaisant en l'état : il contient des variables non significatives et un coefficient de signe incohérent.

7.4 Sélection pas à pas (sujet 1.4.3)

Procédures. Les trois procédures sont appliquées, chacune avec l'AIC et le BIC comme critère :

— **forward** : on part du modèle constant et on ajoute la variable qui diminue le plus le critère ;

— **backward** : on part du modèle complet et on retire la variable dont le retrait diminue le plus le critère ;

— **bidirectionnelle** : à chaque étape, on envisage tous les ajouts et tous les retraits.

Chaque procédure s'arrête quand plus aucun mouvement ne diminue le critère.

Tableau 39 – Comparaison des modèles : indicateurs du sujet sur l'apprentissage, AUC et AR sur le test, nombre de variables non significatives et de coefficients négatifs.

modele	n variables	log vraisemblance	aic	bic	auc	accuracy ratio	auc test	ar test	variables non significatives	coefficients negatifs
complet (14 candidates)	14	-4 078,5	8 187,0	8 291,6	0,6489	0,2978	0,6265	0,2530	3	1
IV ≥ 0,02 seules	5	-4 114,2	8 240,4	8 282,2	0,6337	0,2675	0,6144	0,2288	0	0
forward-aic	11	-4 079,5	8 183,0	8 266,6	0,6484	0,2968	0,6258	0,2515	0	0
forward-bic	8	-4 088,1	8 194,2	8 256,9	0,6456	0,2912	0,6268	0,2536	0	0
backward-aic	11	-4 079,5	8 183,0	8 266,6	0,6484	0,2968	0,6258	0,2515	0	0
backward-bic	8	-4 088,1	8 194,2	8 256,9	0,6456	0,2912	0,6268	0,2536	0	0
both-aic	11	-4 079,5	8 183,0	8 266,6	0,6484	0,2968	0,6258	0,2515	0	0
both-bic	8	-4 088,1	8 194,2	8 256,9	0,6456	0,2912	0,6268	0,2536	0	0

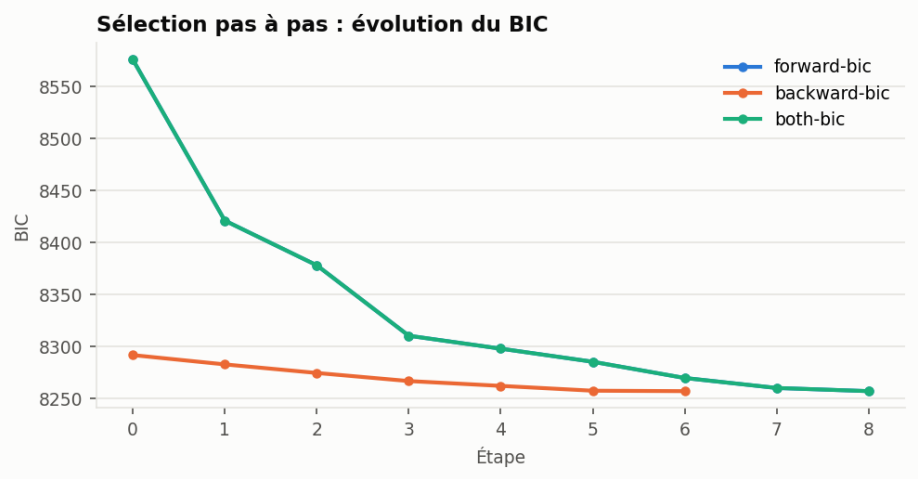


Figure 22 – Évolution du BIC au fil des étapes des trois procédures.

La figure 22 suit le BIC à chaque étape.

— Les procédures forward et bidirectionnelle partent du modèle constant (BIC 8 575,8) et ajoutent les variables dans le même ordre : *Credit Score*, *Term*, *Annual Income*, ESR, DTI, *Home Ownership*, *Maximum Open Credit*, CUR.

— La procédure backward part du modèle complet (BIC 8 291,6) et retire six variables.

— Les trois chemins s'arrêtent au même point, avec un BIC de 8 256,9.

Résultats.

— **Convergence des procédures.** Pour un même critère, les trois procédures aboutissent au même modèle (tableau 39) :

  — **8 variables avec le BIC** : le backward retire successivement *Purpose*, *Current Credit Balance*, *Years of Credit History*, *Years in current job*, *Monthly Debt* et *Current Loan Amount* ;

  — **11 variables avec l'AIC**.

— **Choix du modèle final.** On retient le modèle de BIC minimal parmi ceux dont toutes les variables sont significatives et de coefficient positif : le modèle BIC.

  — Il minimise le BIC (8 256,9).

  — Les trois variables supplémentaires du modèle AIC n'améliorent la log-vraisemblance que de 8,6 points.

  — Elles n'apportent rien en test : AUC de 0,627 pour le modèle BIC contre 0,626 pour le modèle AIC.

— **Apport des candidates faibles.** Le modèle restreint aux 5 variables d'IV $\geq 0{,}02$ est nettement moins bon (BIC 8 282,2, AUC test 0,614). ESR, *Home Ownership* et CUR apportent donc une information significative une fois combinées aux autres, ce qui justifie a posteriori de les avoir conservées comme candidates.

7.5 Modèle final

Tableau 40 – Modèle final : coefficients, erreurs standards, p-values, odds ratios et intervalles de confiance à 95 %.

variable	coefficient	ecart type	z	p-value	odds ratio	or ic bas	or ic haut
const	-1,184	0,028	-42,91	< 0,001	0,306	0,290	0,323
Credit Score	0,460	0,091	5,05	< 0,001	1,584	1,325	1,894
Term	1,019	0,103	9,91	< 0,001	2,772	2,266	3,391
Annual Income	0,627	0,123	5,11	< 0,001	1,873	1,472	2,382
ESR	0,921	0,199	4,62	< 0,001	2,513	1,700	3,713
DTI	0,594	0,114	5,22	< 0,001	1,811	1,449	2,264
Home Ownership	0,948	0,207	4,58	< 0,001	2,580	1,720	3,871
Maximum Open Credit	0,733	0,194	3,78	< 0,001	2,081	1,424	3,041
CUR	0,693	0,200	3,46	< 0,001	2,000	1,351	2,960

Le tableau 40 donne, pour chaque variable du modèle final, le coefficient, son erreur standard, la statistique z, la p-value, l'odds ratio et son intervalle de confiance à 95 %.

Vérifications du sujet.

— **Significativité.** Toutes les variables sont significatives à 1 % (z de 3,5 à 9,9).

— **Absence de forte corrélation.** VIF de 1,01 à 1,35 ; la corrélation maximale entre WoE du modèle vaut 0,376.

— **Cohérence avec le défaut.** Les 8 coefficients sont positifs, entre 0,46 et 1,02.

Tableau 41 – Performance du modèle final sur l'apprentissage et le test.

indicateur	apprentissage	test	ecart
auc	0,6456	0,6268	-0,0188
accuracy_ratio	0,2912	0,2536	-0,0376
log_loss	0,5200	0,5272	0,0071
brier	0,1708	0,1735	0,0027
pd_moyenne	0,2347	0,2308	-0,0039
taux_defaut_observe	0,2347	0,2350	0,0003
accuracy	0,5939	0,5900	-0,0039
precision	0,3144	0,3014	-0,0130
rappel	0,6184	0,5649	-0,0535
specificite	0,5864	0,5977	0,0113
f1	0,4169	0,3931	-0,0238

Tableau 42 – Matrice de confusion du modèle final sur le test (seuil 23,47 %).

	prédit 0	prédit 1
observé 0	899	605
observé 1	201	261

Le tableau 41 met côte à côte les indicateurs du modèle final sur l'apprentissage et sur le test. Le tableau 42 donne la matrice de confusion du test.

Généralisation.

— **Discrimination.** L'AUC passe de 0,646 en apprentissage à 0,627 en test, et l'AR de 0,291 à 0,254. L'écart est plus faible que pour le modèle complet, avec la même performance en test.

— **Calibration.** La PD moyenne du test (23,1 %) correspond au taux observé (23,5 %).

— **Classification** au seuil de 23,47 % : 56,5 % des défauts du test sont détectés, (261 sur 462), pour une spécificité de 59,8 % (899 non-défauts correctement classés sur 1 504) et une précision de 30,1 %. La précision limitée découle d'un pouvoir discriminant modeste, contraint par la faiblesse des variables disponibles (IV maximal de 0,12), et non d'un sur-ajustement.

7.6 Lecture des variables retenues

Tableau 43 – Contribution relative des variables au score (formule de l'annexe).

variable	ecart type terme	contribution
Term	0,2770	22,3 %
Credit Score	0,1689	13,6 %
Annual Income	0,1656	13,3 %
DTI	0,1645	13,3 %
Home Ownership	0,1294	10,4 %
ESR	0,1254	10,1 %
Maximum Open Credit	0,1140	9,2 %
CUR	0,0968	7,8 %

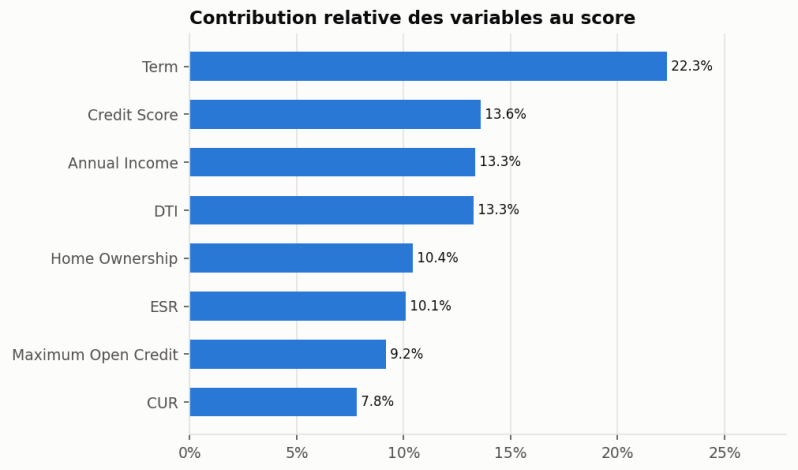


Figure 23 – Contribution relative des variables du modèle final.

En codage WoE, le coefficient de la modalité k de la variable i vaut $\alpha_k = \beta_i \, \mathrm{WoE}_k$. Le terme αX_i est une variable discrète de loi (p_k), et son écart-type est celui que donne l'annexe :

$$\sigma(\alpha_i X_i) = \sqrt{\textstyle\sum_k p_k \alpha_k^2 - \left(\sum_k p_k \alpha_k\right)^2},$$

c'est-à-dire $\sqrt{\mathbb{E}[\alpha^2] - \mathbb{E}[\alpha]^2}$. La contribution relative $C_i = \sigma(\alpha_i X_i) / \sum_j \sigma(\alpha_j X_j)$ mesure la part de la dispersion du score due à chaque variable (tableau 43, figure 23). Le tableau 44 donne le détail de α_k par classe.

Tableau 44 – Contribution de chaque classe au score logistique ($\beta \times$ WoE), avec la part et le taux de défaut de la classe.

variable	classe	part	taux défaut	woe	contribution score
Credit Score	]-inf ; 692]	13,8 %	31,9 %	0,423	0,195
Credit Score	]692 ; 711]	13,1 %	22,3 %	-0,067	-0,031
Credit Score	]711 ; 723]	14,8 %	19,5 %	-0,238	-0,109
Credit Score	]723 ; 734]	12,6 %	25,6 %	0,117	0,054
Credit Score	]734 ; 742]	13,4 %	21,9 %	-0,092	-0,042
Credit Score	]742 ; +inf]	12,8 %	11,9 %	-0,817	-0,376
Credit Score	Manquant	19,5 %	28,6 %	0,269	0,124
Term	Short Term	71,8 %	20,2 %	-0,189	-0,193
Term	Long Term	28,2 %	31,7 %	0,415	0,423
Annual Income	]-inf ; 1 166 543]	40,3 %	26,5 %	0,160	0,100
Annual Income	]1 166 543 ; +inf]	40,3 %	18,0 %	-0,336	-0,211
Annual Income	Manquant	19,5 %	28,6 %	0,269	0,169
ESR	]-inf ; 0.07718]	13,7 %	24,2 %	0,041	0,037
ESR	]0.07718 ; 0.1835]	13,7 %	22,6 %	-0,049	-0,045
ESR	]0.1835 ; 0.295]	13,7 %	21,2 %	-0,129	-0,119
ESR	]0.295 ; 0.3906]	13,7 %	20,7 %	-0,164	-0,151
ESR	]0.3906 ; 0.4848]	13,7 %	21,2 %	-0,129	-0,119
ESR	]0.4848 ; 0.6061]	13,9 %	25,8 %	0,123	0,113
ESR	]0.6061 ; +inf] + Non renseigné	17,7 %	27,4 %	0,208	0,191
DTI	]-inf ; 0.112]	20,1 %	16,2 %	-0,459	-0,273
DTI	]0.112 ; 0.167]	20,1 %	21,2 %	-0,129	-0,077
DTI	]0.167 ; 0.227]	20,1 %	22,4 %	-0,059	-0,035
DTI	]0.227 ; +inf]	20,1 %	29,0 %	0,286	0,170
DTI	Manquant	19,5 %	28,6 %	0,269	0,160
Home Ownership	Home Mortgage	48,9 %	21,0 %	-0,144	-0,137
Home Ownership	Own Home + Rent	51,1 %	25,9 %	0,129	0,122
Maximum Open Credit	]-inf ; 234 850]	20,0 %	23,8 %	0,017	0,012
Maximum Open Credit	]234 850 ; 376 090]	20,0 %	25,8 %	0,124	0,091
Maximum Open Credit	]376 090 ; 566 126]	20,0 %	24,2 %	0,042	0,031
Maximum Open Credit	]566 126 ; 876 920]	20,0 %	25,2 %	0,093	0,068
Maximum Open Credit	]876 920 ; +inf]	20,0 %	18,4 %	-0,309	-0,226
CUR	]-inf ; 0.4974] + Sans plafond	50,4 %	21,0 %	-0,144	-0,100
CUR	]0.4974 ; +inf]	49,6 %	26,0 %	0,136	0,094

— **Term** (22,3 %). Un prêt long ajoute 0,42 au score, un prêt court en retire 0,19 : une durée longue expose plus longtemps à un choc de revenu.

— **Credit Score** (13,6 %). De +0,19 (score ≤ 692) à −0,38 (score > 742). Le coefficient (0,46) est inférieur à 1 parce que la classe ń Manquant ż est partagée avec le revenu et le DTI.

— **Annual Income** (13,3 %). Revenu au-dessus de la médiane : −0,21 ; revenu non renseigné : +0,17.

— **DTI** (13,3 %). De −0,27 (DTI $\leq 0{,}11$) à +0,17 (DTI $> 0{,}23$) : le risque croît avec la part du revenu consacrée à la dette.

— **Home Ownership** (10,4 %). Avoir obtenu un crédit immobilier signale une solvabilité déjà validée par un prêteur.

— **ESR** (10,1 %). Les valeurs élevées et l'ancienneté d'emploi inconnue sont les plus risquées. L'ESR capte surtout la jeunesse de l'historique de crédit (section 4).

— **Maximum Open Credit** (9,2 %). Seuls les plafonds les plus élevés se distinguent (−0,23) : ils sont accordés aux emprunteurs jugés solides.

— **CUR** (7,8 %). Une utilisation supérieure à 50 % du plafond traduit une tension de trésorerie (+0,09 contre −0,10).

8 Robustesse et probabilité de défaut

Sujet 1.5.1 et 1.5.2.
Code : `src.modeling`.
Notebook : partie 7 du notebook `credit_risk.ipynb`.

8.1 Robustesse : 100 modèles bootstrap (sujet 1.5.1)

Le modèle final est réestimé sur 100 échantillons de 7 861 prêts, tirés avec remise dans l'apprentissage (graine 42), avec les mêmes variables et les mêmes WoE.

Principe du bootstrap. Chaque échantillon bootstrap imite un nouveau tirage de la population. La dispersion des 100 estimations $\hat{\beta}^{*(1)}, \ldots, \hat{\beta}^{*(100)}$ approche donc la variabilité d'échantillonnage de $\hat{\beta}$, sans hypothèse de loi. On compare :

— leur moyenne au coefficient initial (biais) ;

— leur écart-type à l'écart-type asymptotique de la régression, obtenu par l'inverse de l'information de Fisher (annexe A.9) ;

— l'intervalle percentile $[\hat{\beta}^*_{(2{,}5\%)} ; \hat{\beta}^*_{(97{,}5\%)}]$ à la valeur 0.

Le tableau 45 rassemble ces indicateurs. La figure 24 représente la distribution des 100 coefficients de chaque variable.

Tableau 45 – Coefficients du modèle initial et des 100 modèles bootstrap : moyenne, écart-type, écart-type asymptotique, biais, intervalle percentile à 95 % et part de même signe.

variable	coefficient initial	moyenne bootstrap	ecart type bootstrap	ecart type asymptotique	biais	percentile 2 5	percentile 97 5	part meme signe
const	-1,1836	-1,1779	0,0288	0,0276	0,0057	-1,227	-1,125	100 %
Credit Score	0,4599	0,4630	0,0950	0,0912	0,0031	0,273	0,629	100 %
Term	1,0194	1,0110	0,0973	0,1029	-0,0084	0,838	1,201	100 %
Annual Income	0,6274	0,6064	0,1234	0,1227	-0,0210	0,361	0,848	100 %
ESR	0,9214	0,9209	0,1977	0,1992	-0,0005	0,564	1,321	100 %
DTI	0,5941	0,6014	0,1089	0,1137	0,0073	0,414	0,795	100 %
Home Ownership	0,9479	0,9721	0,2257	0,2069	0,0243	0,584	1,376	100 %
Maximum Open Credit	0,7327	0,7386	0,1876	0,1936	0,0059	0,355	1,056	100 %
CUR	0,6931	0,6552	0,1914	0,2001	-0,0379	0,307	1,018	100 %

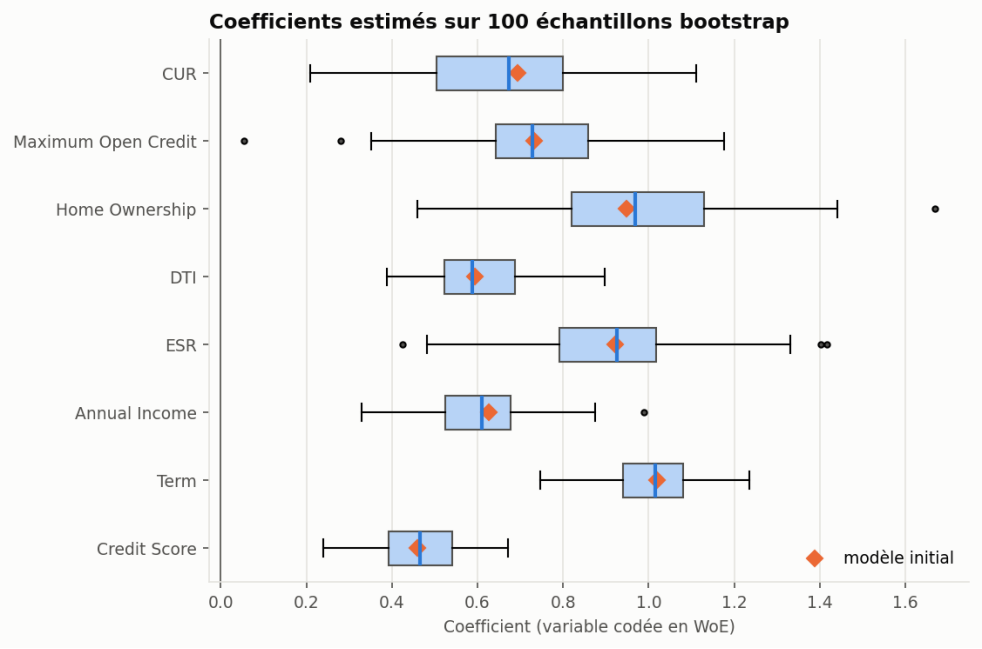


Figure 24 – Distribution des coefficients sur les 100 échantillons bootstrap (losange : modèle initial).

— **Biais négligeable.** La moyenne bootstrap reste proche du coefficient initial : le biais maximal est celui de CUR ($-0{,}038$, soit 5,5 % de son coefficient).

— **Erreurs standards fiables.** L'écart-type bootstrap retrouve l'écart-type asymptotique de la régression, avec un rapport compris entre 0,95 et 1,09. Les tests de significativité sont donc fiables.

— **Signes stables.** Chaque coefficient est positif dans 100 % des échantillons, et aucun intervalle percentile à 95 % ne contient 0.

— **Précision variable.** *Term* est le coefficient le plus précis (coefficient de variation 0,10). Les variables à IV faible, CUR et *Maximum Open Credit*, sont les moins précises (coefficients de variation de 0,29 et 0,25).

— **Performance stable.** Appliqués au test, les 100 modèles ont une AUC comprise entre 0,621 et 0,629.

Le modèle est donc **robuste**.

8.2 Score et probabilité de défaut (sujet 1.5.2)

Pour chaque emprunteur, le score et la PD sont calculés explicitement à partir des coefficients :

$$S_i = \beta_0 + \sum_{j=1}^{p} \beta_j X_{ij}, \qquad \mathrm{PD}_i = \frac{1}{1+\exp(-S_i)} = \frac{\exp(S_i)}{1+\exp(S_i)},$$

où X_{ij} est le WoE de la classe de l'emprunteur i pour la variable j. Ce calcul redonne les prédictions du logiciel à 10^{-16} près, et toutes les PD sont comprises entre 0 et 1.

Exemple de calcul. Le premier emprunteur de l'apprentissage cumule des WoE négatifs :

— un prêt court ($-0{,}19$) ;

— un revenu supérieur à la médiane ($-0{,}34$) ;

— un DTI inférieur à 0,11 ($-0{,}46$).

Son score vaut $S = -2{,}02$, d'où une PD de 11,7 %.

Tableau 46 – Statistiques descriptives et quantiles des PD.

statistique	apprentissage	test
n	7 861	1 966
moyenne	23,47 %	23,08 %
ecart_type	9,41 %	9,40 %
min	5,47 %	5,47 %
q01	6,83 %	7,02 %
q05	9,72 %	9,37 %
q10	11,82 %	11,53 %
q25	16,35 %	15,90 %
q50	22,49 %	22,00 %
q75	29,36 %	29,12 %
q90	36,05 %	35,47 %
q95	40,63 %	40,29 %
q99	48,04 %	48,67 %
max	55,04 %	55,04 %

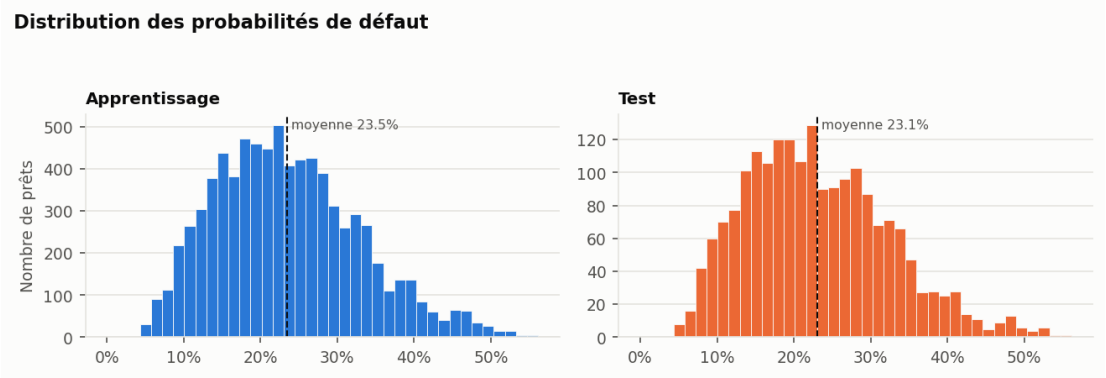


Figure 25 – Distribution des PD sur l'apprentissage et le test.

Le tableau 46 et la figure 25 décrivent la distribution des PD sur l'apprentissage et sur le test.

Distribution des PD.

— **Moyenne.** Elle vaut 23,5 % en apprentissage, exactement le taux de défaut observé, et 23,1 % en test. L'égalité en apprentissage n'est pas une coïncidence : la condition du premier ordre en β_0, $\partial\ell/\partial\beta_0 = \sum_i (y_i - p_i) = 0$, impose $\bar{p} = \bar{y}$ dès que le modèle contient une constante (annexe A.7).

— **Étendue.** Les PD vont de 5,5 % à 55,0 %. 90 % des emprunteurs ont une PD comprise entre 9,7 % et 40,6 %.

— **Concentration.** La distribution est resserrée autour de la moyenne (écart-type de 9,4 points). C'est la traduction directe d'un pouvoir discriminant modeste.

Tableau 47 – PD moyenne et taux de défaut observé par décile de PD (test).

classe	n	pd moyenne	taux observe
1	197	9,3 %	11,2 %
2	197	13,2 %	12,7 %
3	197	15,9 %	19,8 %
4	196	18,4 %	18,4 %
5	196	20,8 %	23,5 %
6	197	23,3 %	26,4 %
7	196	26,3 %	24,5 %
8	197	29,2 %	26,9 %
9	197	33,0 %	32,5 %
10	196	41,4 %	39,3 %

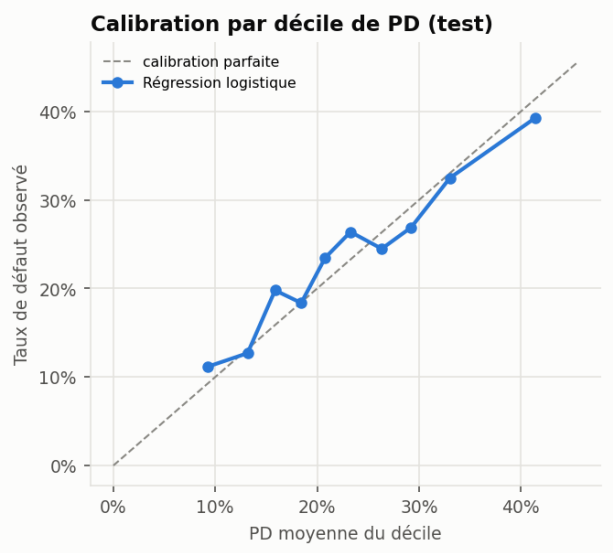


Figure 26 – Calibration de la régression logistique par décile de PD sur le test (diagonale : calibration parfaite).

Calibration. Le tableau 47 et la figure 26 comparent, pour chaque décile de PD du test, la PD moyenne au taux de défaut observé. Sur le test, le taux de défaut observé croît de 11,2 % (premier décile) à 39,3 % (dernier décile), et les PD moyennes suivent (9,3 % à 41,4 %). L'écart maximal, environ 4 points (au 3e décile), reste compatible avec la taille des déciles. Pour un taux de l'ordre de 20 % sur 197 prêts, l'écart-type d'échantillonnage vaut $\sqrt{0{,}2 \times 0{,}8/197} \approx 2{,}8$ points. Les PD sont donc bien calibrées.

9 XGBoost et comparaison des modèles

Sujet 1.5.3.
Code : `src.xgb_model`.
Notebook : partie 8 du notebook `credit_risk.ipynb`.

9.1 Construction (sujet 1.5.3)

XGBoost construit séquentiellement des arbres de décision peu profonds. Le score s'écrit $F_M(x) = \sum_{m=1}^{M} \eta\, f_m(x)$, avec η le pas d'apprentissage. Chaque arbre f_m est ajusté pour diminuer la log-vraisemblance binomiale négative (la même que celle de la régression logistique) à partir de son gradient et de sa dérivée seconde au point F_{m-1}, avec une pénalité sur la complexité des arbres. La PD vaut $1/(1+e^{-F_M(x)})$. Contrairement à celle-ci, il peut capter des effets non linéaires et des interactions.

Données et variables. Le modèle est construit sur le **même apprentissage** et avec les **8 variables du modèle logistique final**, selon deux codages :

- **valeurs traitées** (codage principal) :
  - les variables quantitatives gardent leurs valeurs continues, et leurs manquants sont gérés nativement par l'algorithme ;
  - les variables qualitatives deviennent des indicatrices ;
- **WoE** (analyse de sensibilité) : les mêmes colonnes que la régression logistique.

Hyperparamètres. Ils sont choisis par recherche sur grille (72 combinaisons), en validation croisée stratifiée à 5 plis sur l'apprentissage seul, avec l'AUC comme critère :

— nombre d'arbres : 100, 300, 600 ;

— profondeur : 1 à 4 ;

— pas d'apprentissage : 0,01, 0,05, 0,1 ;

— poids minimal de feuille : 1, 10 ;

— sous-échantillonnage des observations et des variables : 0,8.

Tableau 48 – Hyperparamètres retenus et AUC de validation croisée.

hyperparametre	valeurs traitées	WoE
colsample_bytree	0,8	0,8
learning_rate	0,05	0,1
max_depth	1	2
min_child_weight	10	1
n_estimators	300	100
subsample	0,8	0,8
auc_validation_croisee	0,6475	0,6447

Le tableau 48 donne la combinaison retenue pour chacun des deux codages, avec son AUC moyenne de validation croisée.

Configuration retenue. Sur les valeurs traitées, la meilleure combinaison utilise **300 arbres de profondeur 1**, avec un pas de 0,05 (AUC de validation croisée 0,6475).

— Les six meilleures combinaisons ont toutes une profondeur de 1. Les arbres plus profonds sur-ajustent (AUC d'apprentissage de 0,711 contre 0,669) sans gagner en validation.

— Un arbre de profondeur 1 ne fait intervenir qu'une variable : le modèle retenu est une *somme d'effets univariés non linéaires*, sans interaction.

9.2 Comparaison sur le même échantillon de test

Tableau 49 – Comparaison sur le test (1 966 prêts) : discrimination, qualité probabiliste et niveau moyen des PD.

modele	auc	accuracy ratio	log vraisemblance	log loss	brier	pd moyenne	taux défaut observe
Régression logistique	0,6268	0,2536	-1 036,4	0,5272	0,1735	23,08 %	23,50 %
XGBoost (valeurs traitées)	0,6454	0,2908	-1 028,3	0,5230	0,1719	23,11 %	23,50 %
XGBoost (WoE)	0,6318	0,2636	-1 034,3	0,5261	0,1731	23,13 %	23,50 %

Tableau 50 – Écart d'AUC avec la régression logistique : estimation, intervalle de confiance bootstrap à 95 % (1 000 tirages) et part des tirages où l'écart est négatif.

modele	ecart auc	ic bas	ic haut	part ecarts negatifs
XGBoost (valeurs traitées)	0,0186	0,0055	0,0307	0,1 %
XGBoost (WoE)	0,0050	-0,0055	0,0150	15,1 %

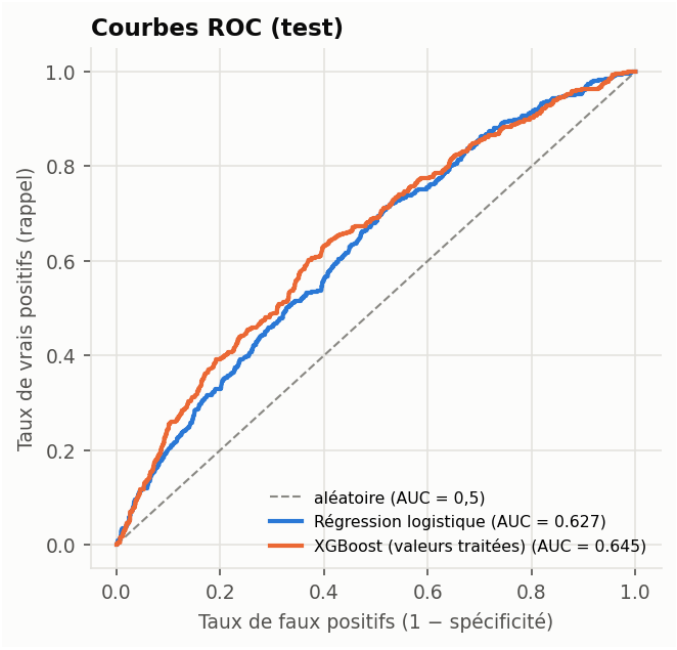


Figure 27 – Courbes ROC sur le test.

Le tableau 49 compare les trois modèles sur le même test. Le tableau 50 teste l'écart d'AUC par bootstrap : 1 000 rééchantillonnages du test, intervalle percentile à 95 %. La figure 27 superpose les courbes ROC : celle de XGBoost se situe au-dessus de celle de la régression logistique surtout pour des taux de faux positifs compris entre 0,1 et 0,4 environ ; les deux courbes se rejoignent ensuite.

Discrimination.

- **XGBoost sur les valeurs traitées** est meilleur sur tous les critères : AUC 0,645 contre 0,627, AR 0,291 contre 0,254, log-vraisemblance et score de Brier plus favorables. Le gain d'AUC (+0,019) est significatif, avec un intervalle de confiance à 95 % de [+0,006 ; +0,031], mais il est modeste. Avec des arbres de profondeur 1, il provient de seuils plus fins sur les variables continues, et non d'interactions.
- **XGBoost sur les WoE** ne fait pas significativement mieux que la régression logistique (+0,005, IC [−0,006 ; +0,015]). Une fois les variables résumées par leurs classes, il reste peu d'interactions exploitables.
- **Sur-ajustement.** La baisse d'AUC entre apprentissage et test est comparable pour la régression logistique (−0,019) et pour XGBoost (−0,021).

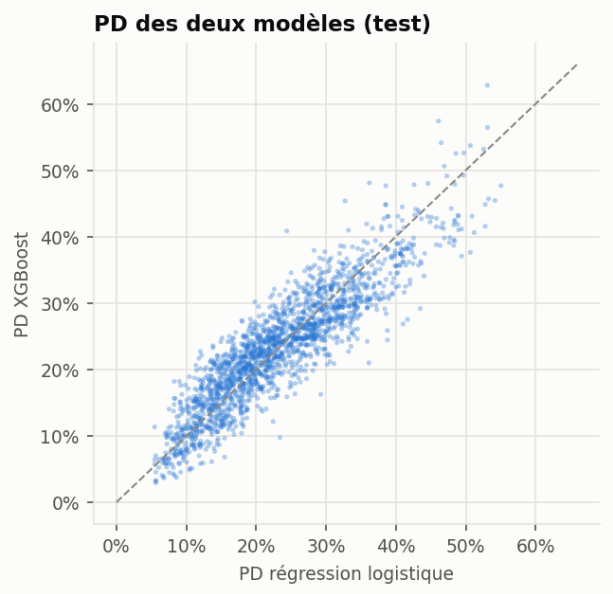


Figure 28 – PD des deux modèles pour les emprunteurs du test.

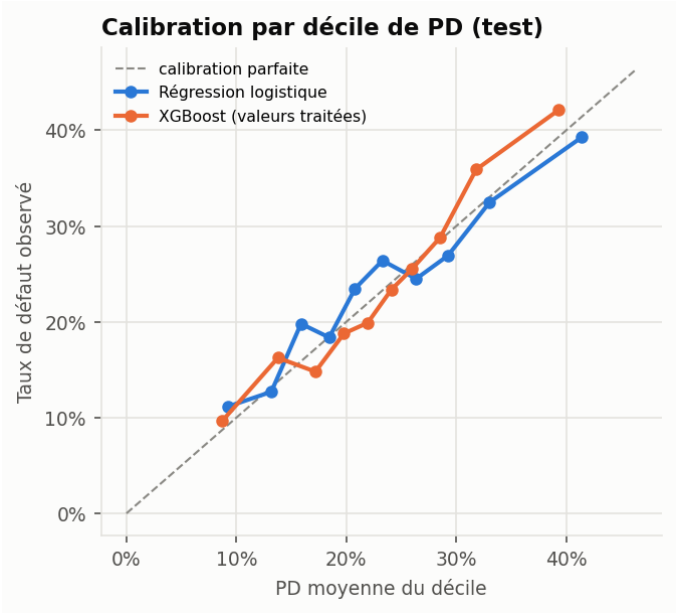


Figure 29 – Calibration par décile de PD (test).

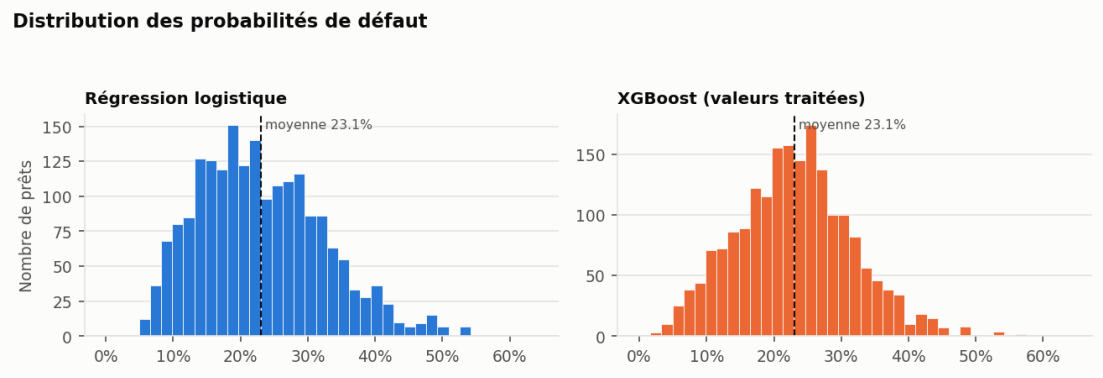


Figure 30 – Distribution des PD des deux modèles sur le test.

La figure 28 confronte les PD des deux modèles, emprunteur par emprunteur : le nuage suit la diagonale avec une dispersion modérée. La figure 30 compare leurs distributions, et la figure 29 leur calibration par décile.

Comparaison des PD.

— **Concordance.** Les PD des deux modèles sont fortement corrélées (Pearson 0,90). L'écart absolu moyen est de 3,3 points, et le 95e percentile de l'écart de 7,8 points.

— **Forme des distributions.** XGBoost produit des PD plus extrêmes aux bornes (2,9 % à 62,8 %, contre 5,5 % à 55,0 %), mais plus resserrées au centre (écart-type de 8,7 points contre 9,4).

— **Calibration.** Elle est bonne pour les deux modèles : PD moyenne de 23,1 % pour un taux observé de 23,5 %.

— **Importance des variables.** L'ordre est cohérent avec les contributions logistiques : *Term*, *Annual Income*, *DTI* et *Credit Score* dominent.

Tableau 51 – Importance des variables XGBoost (gain).

variable	importance gain
Term_Short_Term	22,3 %
Annual_Income	19,6 %
DTI	13,2 %
Credit_Score	12,2 %
CUR	9,7 %
Home_Ownership_Rent	9,6 %
ESR	7,1 %
Maximum_Open_Credit	6,2 %
Home_Ownership_Own_Home	0,0 %

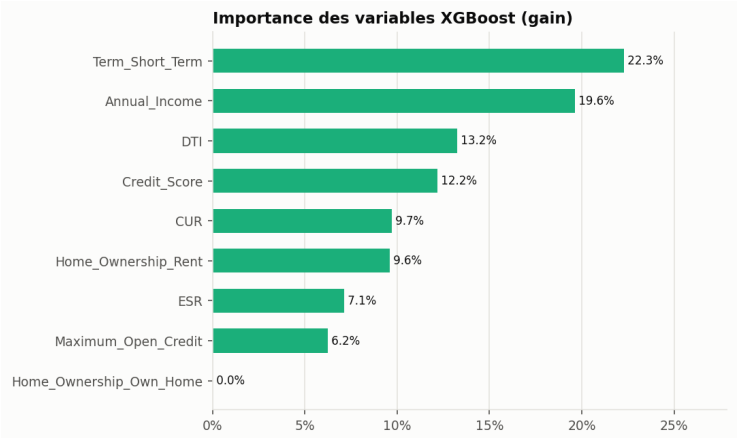


Figure 31 – Importance des variables XGBoost (part du gain total).

Le tableau 51 et la figure 31 mesurent l'importance de chaque variable par sa part du gain total apporté par les divisions qui l'utilisent.

— *Term* (22,3 %), *Annual Income* (19,6 %), *DTI* (13,2 %) et *Credit Score* (12,2 %) dominent.

— L'indicatrice *Own Home* n'est jamais utilisée : la distinction utile oppose *Rent* à *Home Mortgage*.

9.3 Quel modèle privilégier dans un contexte réglementé ?

Tableau 52 – Comparaison qualitative des deux modèles.

Critère	Régression logistique (WoE)	XGBoost
Discrimination (test)	AUC 0,627	AUC 0,645 (+0,019, significatif mais modeste)
Interprétabilité	Contribution de chaque classe au score ($\beta \times$WoE), odds ratios	300 arbres ; explications seulement par outils post-hoc
Sens économique	Coefficients positifs : risque croissant garanti par classe	Aucune contrainte de monotonie ni de signe
Robustesse démontrée	100 bootstraps : coefficients et signes stables	Sensible aux hyperparamètres ; robustesse plus difficile à démontrer
Explication d'un refus	Directe, par variable	Indirecte, approximative
Validation et suivi	Standard (PSI, backtesting par classe)	Plus lourds
Exigences de supervision	Pratique éprouvée et acceptée	Admissible, mais charge de justification élevée

Recommandation : la régression logistique est le modèle à privilégier comme modèle de PD dans un contexte réglementé, pour trois raisons.

1. **Le gain de XGBoost est modeste.** +0,019 d'AUC, sur un portefeuille faiblement discriminable. Il ne compense pas la perte d'interprétabilité, de traçabilité et de contrôle du sens économique attendus d'un modèle de notation interne. Une meilleure performance prédictive ne rend pas, à elle seule, un modèle préférable.
2. **L'origine du gain est identifiée.** Il vient de seuils plus fins, pas d'interactions. Il peut donc être en partie récupéré dans la régression logistique, en affinant la discrétisation des variables où XGBoost trouve des seuils utiles (revenu, DTI, score), sans renoncer à la transparence.
3. **XGBoost reste utile comme modèle challenger.** Il confirme qu'aucune interaction majeure n'est négligée par le modèle logistique (le XGBoost sur WoE ne fait pas mieux), oriente les améliorations de la discrétisation, et sert de référence de performance lors du suivi.

10 Conclusion

Le modèle de probabilité de défaut retenu est une **régression logistique à 8 variables codées en WoE** :

— durée du prêt ;

— score de crédit ;

— revenu annuel ;

— DTI ;

— statut d'occupation du logement ;

— ESR ;

— plafond de crédit ;

— taux d'utilisation du crédit (CUR).

Les principaux résultats sont les suivants.

— **Qualité des données.** Deux artefacts révélant directement l'issue du prêt ont été identifiés et neutralisés : une valeur sentinelle du montant, portée uniquement par des prêts

remboursés, et un *Credit Score* multiplié par 10, porté uniquement par des défauts. Sans cette correction, le modèle aurait paru presque parfait tout en étant inutilisable.

— **Absence de fuite d'information.** Toutes les règles de transformation sont apprises sur l'échantillon d'apprentissage seul : bornes, imputations, discrétisation, WoE, sélection. Les deux échantillons sont représentatifs (PSI $< 0{,}01$).

— **Pouvoir discriminant.** Il est modeste, avec une AUC test de 0,627 (AR 0,254). Cela reflète la faiblesse des variables disponibles (IV maximal de 0,12), pas un défaut de méthode : XGBoost, plus flexible, n'atteint que 0,645.

— **Robustesse.** Les coefficients sont stables et de signe constant sur 100 échantillons bootstrap, et les PD sont bien calibrées par décile.

— **Choix du modèle.** Dans un contexte réglementé, la régression logistique est préférée à XGBoost pour sa transparence et son contrôle du sens économique. XGBoost sert de modèle challenger.

Corrections apportées à l'énoncé. Les formules de l'IV et du PSI de l'annexe, telles qu'écrites, sont toujours négatives ou nulles. On a utilisé leur forme positive, qui en est l'opposé exact et qui est cohérente avec les tables d'interprétation.

Limites et pistes.

— La censure de l'ancienneté d'emploi à 10 ans limite l'ESR et l'IES.

— Le taux de défaut élevé de l'échantillon (23,5 %) impose de recalibrer les PD avant tout usage sur un portefeuille réel.

— Une discrétisation plus fine des variables continues, guidée par les seuils trouvés par XGBoost, pourrait récupérer une partie de son avantage sans renoncer à l'interprétabilité.

A Démonstrations mathématiques

Cette annexe justifie les propriétés utilisées dans le rapport. Les seules valeurs numériques qui y figurent sont des constantes mathématiques (quantiles de la loi normale, logarithmes) ou des rappels de résultats calculés dans les sections précédentes.

A.1 Signe de l'IV et du PSI

Propriété. Soient $b = (b_i)$ et $g = (g_i)$ deux distributions sur les mêmes classes, strictement positives. Alors

$$\sum_i (g_i - b_i) \ln \frac{b_i}{g_i} \leq 0 \qquad \text{et} \qquad \mathrm{IV} = \sum_i (b_i - g_i) \ln \frac{b_i}{g_i} \geq 0,$$

avec égalité si et seulement si $b = g$.

Démonstration. La fonction ln est strictement croissante. Si $b_i > g_i$, alors $\ln(b_i/g_i) > 0$ et $b_i - g_i > 0$; si $b_i < g_i$, les deux facteurs sont négatifs ; si $b_i = g_i$, le terme est nul. Chaque terme $(b_i - g_i)\ln(b_i/g_i)$ est donc positif ou nul, et nul seulement si $b_i = g_i$. L'expression de l'énoncé en est l'opposé exact, d'où son signe. □

Interprétation. En développant,

$$\mathrm{IV} = \sum_i b_i \ln \frac{b_i}{g_i} + \sum_i g_i \ln \frac{g_i}{b_i} = \mathrm{KL}(b\|g) + \mathrm{KL}(g\|b),$$

soit la divergence de Jeffreys entre la distribution des défauts et celle des non-défauts dans les classes. Le même calcul s'applique au PSI avec (P, Q) à la place de (g, b) : $\mathrm{PSI} = \sum_i (Q_i - P_i)\ln(Q_i/P_i) = \mathrm{KL}(Q\|P) + \mathrm{KL}(P\|Q) \geq 0$, et la formule est symétrique en P et Q. Les écritures de l'énoncé, $\sum(\mathrm{Good}_i/\mathrm{Good} - \mathrm{Bad}_i/\mathrm{Bad})\ln\frac{\mathrm{Bad}_i/\mathrm{Bad}}{\mathrm{Good}_i/\mathrm{Good}}$ et $\sum(P_i - Q_i)\ln(Q_i/P_i)$, sont donc toujours négatives ou nulles. Le code utilise leurs opposés, conformes aux tables d'interprétation.

A.2 T de Tschuprow et nombre de classes

Avec une cible binaire ($c = 2$), $\min(r-1, c-1) = 1$, d'où $V = \sqrt{\chi^2/n}$ et

$$T = \sqrt{\frac{\chi^2}{n\sqrt{r-1}}} = \frac{V}{(r-1)^{1/4}}.$$

Passer de r à $r' > r$ classes n'augmente T que si $V'/V > ((r'-1)/(r-1))^{1/4}$. Par exemple, de 2 à 10 classes, il faut multiplier V par $9^{1/4} \approx 1{,}73$. Le χ^2 d'un découpage plus fin est en général plus élevé, car il capte aussi les fluctuations aléatoires entre classes : son espérance sous l'hypothèse d'indépendance vaut $r - 1$. Maximiser T revient donc à rechercher le meilleur compromis entre association et finesse du découpage.

A.3 Proportions d'outliers sous la loi normale et masquage

Règle des trois écarts-types. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, on a $P(|X-\mu| > 3\sigma) = 2\,(1-\Phi(3)) \approx 0{,}0027$, soit $0{,}27\,\%$.

Méthode IQR. Pour la loi normale, $Q_1 = \mu - 0{,}6745\,\sigma$ et $Q_3 = \mu + 0{,}6745\,\sigma$, donc $\mathrm{IQR} = 1{,}349\,\sigma$. Les clôtures valent $Q_3 + 1{,}5\,\mathrm{IQR} = \mu + 2{,}698\,\sigma$ (et symétriquement en bas), d'où une proportion attendue $2\,(1 - \Phi(2{,}698)) \approx 0{,}0070$, soit $0{,}70\,\%$. Sous normalité, la méthode IQR est donc plus sévère que la règle des 3σ. Ses clôtures sont plus proches de la médiane, ce qui explique qu'en pratique les outliers à $3s$ soient inclus dans les outliers IQR (tableau 12).

Masquage (inégalité de Samuelson). Pour tout échantillon $x_1, \ldots, x_n$ d'écart-type empirique s (dénominateur $n-1$),

$$|x_j - \bar{x}| \leq s\,\frac{n-1}{\sqrt{n}} \qquad \text{pour tout } j.$$

Démonstration. Posons $d_i = x_i - \bar{x}$, avec $\sum_i d_i = 0$. Alors $d_j = -\sum_{i \neq j} d_i$. Par l'inégalité de Cauchy-Schwarz, $d_j^2 \leq (n-1)\sum_{i\neq j} d_i^2 = (n-1)((n-1)s^2 - d_j^2)$, d'où $n\,d_j^2 \leq (n-1)^2 s^2$. □

Conséquence. Avec $n = 5$, aucune observation ne peut dépasser $4/\sqrt{5} \approx 1{,}79$ écarts-types : la règle des $3s$ ne signale jamais rien, aussi extrême que soit la valeur. C'est le cas vérifié par le test unitaire (partie 9 du notebook) sur l'échantillon $(1, 2, 3, 4, 1000)$. Plus généralement, une valeur extrême augmente s et éloigne d'autant la borne $\bar{x} + 3s$. C'est ce qui se produit pour *Maximum Open Credit*.

A.4 Plafonnement, classes de quantiles et ratios

Propriété. Soit $c = q_{0,99}$ le 99e percentile de X et $\tilde{X} = \min(X, c)$. Les classes de déciles de $\tilde{X}$ sont identiques à celles de X.

Démonstration. $x \mapsto \min(x, c)$ est croissante, donc elle préserve l'ordre (au sens large) des observations. Les déciles $q_{0,1}, \ldots, q_{0,9}$ sont inférieurs ou égaux à c, et la transformation laisse inchangées toutes les valeurs $\leq c$. Les bornes des neuf premiers déciles ne changent donc pas. Les valeurs plafonnées, supérieures à $c \geq q_{0,9}$, restent dans le dernier décile. Aucune observation ne change de classe. □

Cas d'un ratio. En général, $\min(A, c_A)/\min(B, c_B) \neq \min(A/B, c)$, et aucune transformation monotone du ratio ne permet de passer de l'un à l'autre. Si seul B est plafonné, le ratio augmente ; si seul A l'est, il diminue. L'ordre des ratios n'est donc plus préservé. C'est ce que mesure le tableau 19, et c'est pourquoi les ratios sont calculés avant tout plafonnement.

A.5 Imputation hot-deck du montant

Soit m le nombre de prêts dont le montant est imputé, tous non défaillants (ils proviennent de la sentinelle), et q_i la part de la classe i dans la distribution des montants observés de l'apprentissage. Le tirage étant fait dans cette distribution, chaque prêt imputé tombe dans la classe i avec probabilité q_i. En espérance, la classe i reçoit $m\,q_i$ non-défauts supplémentaires et aucun défaut.

Les classes de quantiles ayant des parts q_i voisines (environ $1/k$), l'ajout est quasi uniforme entre classes. Il ne crée donc pas de classe artificiellement sûre, contrairement à une modalité ń Manquant ż (taux de défaut nul) ou à une imputation par la médiane (tous les ajouts dans une seule classe). Il atténue seulement les WoE vers 0. Cela explique que l'IV de *Current Loan Amount* reste faible (0,0188) : la variable ne porte plus le signal artificiel de la sentinelle.

A.6 WoE et régression logistique

Soit X une variable discrétisée de classes i. Par la formule de Bayes,

$$\frac{P(D=1 \mid X=i)}{P(D=0 \mid X=i)} = \frac{P(X=i \mid D=1)\,P(D=1)}{P(X=i \mid D=0)\,P(D=0)} = \frac{b_i}{g_i} \cdot \frac{\text{Bad}}{\text{Good}}.$$

En passant au logarithme :

$$\ln \frac{P(D=1 \mid X=i)}{P(D=0 \mid X=i)} = \ln \frac{\text{Bad}}{\text{Good}} + \text{WoE}_i.$$

La régression logistique univariée sur le WoE, logit $= \beta_0 + \beta_1 \text{WoE}_i$, reproduit donc exactement les cotes de chaque classe avec $\beta_0 = \ln(\text{Bad}/\text{Good})$ et $\beta_1 = 1$. Le maximum de vraisemblance étant atteint lorsque les PD ajustées égalent les taux observés par classe, ces valeurs sont les estimateurs.

Dans un modèle multivarié, $\beta_j = 1$ signifie que la variable garde tout son effet univarié, et $0 < \beta_j < 1$ qu'une partie est expliquée par les autres variables. Un $\beta_j < 0$ signifierait un effet inversé par rapport au profil univarié, incohérent : c'est le critère de signe utilisé pour choisir le modèle final.

A.7 Maximum de vraisemblance et PD moyenne

La log-vraisemblance $\ell(\beta) = \sum_i [y_i \ln p_i + (1-y_i)\ln(1-p_i)]$, avec $p_i = 1/(1+e^{-x_i^\top \beta})$, a pour gradient

$$\frac{\partial \ell}{\partial \beta} = \sum_i (y_i - p_i)\, x_i,$$

car $\partial p_i/\partial \beta = p_i(1-p_i)x_i$. Elle est concave, de hessienne $-\sum_i p_i(1-p_i)x_i x_i^\top$, ce qui garantit l'unicité du maximum lorsqu'il existe.

La composante associée à la constante ($x_{i0} = 1$) donne, à l'optimum, $\sum_i (y_i - p_i) = 0$, soit $\frac{1}{n}\sum_i p_i = \frac{1}{n}\sum_i y_i$. La PD moyenne sur l'apprentissage est donc exactement égale au taux de défaut observé, ce que l'on constate (23,5 %, tableau 46).

A.8 AUC et Accuracy Ratio

L'AUC est l'aire sous la courbe ROC. Elle est égale à la probabilité qu'un défaut tiré au hasard ait un score supérieur à celui d'un non-défaut tiré au hasard, les ex-aequo comptant pour moitié (statistique de Mann-Whitney normalisée).

L'Accuracy Ratio est le rapport entre l'aire comprise entre la courbe CAP du modèle et la diagonale, et la même aire pour un modèle parfait. On montre qu'il vaut $\mathrm{AR} = 2\,\mathrm{AUC} - 1$:

— un modèle aléatoire (AUC = 0,5) a un AR nul ;

— un modèle parfait a un AR de 1.

C'est la relation utilisée par le code (`accuracy_ratio`).

A.9 Écarts-types asymptotiques et bootstrap

Sous les conditions usuelles, l'estimateur du maximum de vraisemblance est asymptotiquement gaussien :

$$\hat{\beta} \approx \mathcal{N}\big(\beta,\, I(\hat{\beta})^{-1}\big), \qquad I(\beta) = \sum_{i} p_i(1-p_i)x_i x_i^{\top}.$$

Les écarts-types publiés par la régression sont les racines des termes diagonaux de $I(\hat{\beta})^{-1}$. Le bootstrap estime la même dispersion sans hypothèse de loi, à partir de la variabilité des réestimations.

La proximité des deux écarts-types (rapport compris entre 0,95 et 1,09, tableau 45) valide donc l'approximation asymptotique, et avec elle les p-values du modèle. L'intervalle percentile $[\hat{\beta}^{*}_{(2{,}5\%)};\, \hat{\beta}^{*}_{(97{,}5\%)}]$ est un intervalle de confiance à 95 % qui ne suppose pas la normalité.

A.10 Découpage stratifié

Le tirage stratifié répartit séparément les défauts et les non-défauts : 20 % de chaque groupe va au test. Le test contient donc environ $0{,}2 \times 2\,307 \approx 461{,}4$ défauts, arrondis à 462, sur 1 966 prêts. Son taux de défaut ne diffère de celui de la population que par l'arrondi, alors qu'un tirage aléatoire simple le ferait varier.

Ce taux suit une loi hypergéométrique d'écart-type proche de $\sqrt{p(1-p)/n_{\text{test}} \cdot (1 - n_{\text{test}}/N)} \approx 0{,}86$ point de pourcentage. C'est la raison de la stratification demandée par le sujet.

Liste des tableaux

1 Principales caractéristiques de la base brute. 4
2 Distribution de la variable cible (base brute). 4
3 Variables les plus concentrées : part et taux de défaut de la modalité dominante, p-value du χ^2. 7
4 Valeurs manquantes par codage, nature, et taux de défaut selon que la valeur est manquante ou renseignée (base brute). 8
5 Contrôles de plages et de cohérence entre variables : effectif, part et taux de défaut des lignes en anomalie (base brute). 9
6 Contrôle des doublons. 11
7 Traitements déterministes, dans leur ordre d'application. 11
8 Synthèse par variable : taux de manquants avant et après traitement, traitement et décision. 12
9 Découpage apprentissage / test stratifié. 12
10 Propriétés des deux méthodes de détection. 13
11 Bornes et outliers détectés par chaque méthode (apprentissage). 16
12 Recouvrement des deux méthodes : observations signalées par les deux, par une seule, indice de Jaccard. 17
13 Plafonds de crédit extrêmes en ordre de grandeur et ratio au revenu annuel (case vide : revenu manquant). 18
14 Impact des stratégies sur *Maximum Open Credit* (apprentissage). 19
15 Lignes conservées si l'on supprime toute ligne signalée sur au moins une variable. . 19
16 Bornes de plafonnement (P99 de l'apprentissage) et valeurs plafonnées par échantillon. 20
17 Synthèse des décisions par variable. 20
18 Signification économique et effet attendu sur la probabilité de défaut. 21
19 Déformation des ratios s'ils étaient calculés sur les montants plafonnés (apprentissage). 22
20 Valeurs non définies par variable et par cause. 22
21 Prêts sans plafond de crédit (apprentissage). 23
22 Distribution des variables dérivées (apprentissage, IES plafonné). 23
23 Effet attendu et effet observé (premier et dernier quintiles, corrélation de Spearman). 24
24 Paires impliquant une variable dérivée avec $|r| > 0{,}4$. 25
25 Découpages candidats de *Credit Score* : χ^2, χ^2/n et T avant regroupement, nombre de classes et T après regroupement. 27
26 Découpage retenu pour chaque variable quantitative : nombre de quantiles, nombre de classes, χ^2 normalisé, T et parts minimales. 29
27 Classes finales des variables qualitatives : effectif, part des observations et des défauts, taux de défaut et WoE (apprentissage). 29
28 IV, interprétation (table 3 de l'annexe), T de Tschuprow et V de Cramér des 20 variables candidates (apprentissage). 30
29 WoE et contribution à l'IV par classe de *Credit Score*. 32
30 WoE et contribution à l'IV par classe de DTI. 33
31 WoE et contribution à l'IV de *Term*. 33
32 Matrice des PSI entre les quatre échantillons bootstrap (table 2 du sujet). 34
33 Stabilité du lien avec le défaut sur les quatre échantillons : IV (moyenne, écart-type, coefficient de variation), classes dont le WoE change de signe, concordance minimale de l'ordre des classes. 35
34 V de Cramér avec la cible, IV, p-value du χ^2 et rangs. 36
35 Paires avec V $> 0{,}4$: V hors classes ń manquant ż, corrélation des variables codées en WoE et décision. 37

36 Décision et justification pour chacune des 20 variables. 39
37 PSI apprentissage/test et test d'homogénéité du χ^2 par variable. 40
38 Modèle logistique sur les 14 variables candidates (apprentissage). 41
39 Comparaison des modèles : indicateurs du sujet sur l'apprentissage, AUC et AR sur le test, nombre de variables non significatives et de coefficients négatifs. 41
40 Modèle final : coefficients, erreurs standards, p-values, odds ratios et intervalles de confiance à 95 %. 43
41 Performance du modèle final sur l'apprentissage et le test. 43
42 Matrice de confusion du modèle final sur le test (seuil 23,47 %). 43
43 Contribution relative des variables au score (formule de l'annexe). 44
44 Contribution de chaque classe au score logistique ($\beta \times$ WoE), avec la part et le taux de défaut de la classe. 45
45 Coefficients du modèle initial et des 100 modèles bootstrap : moyenne, écart-type, écart-type asymptotique, biais, intervalle percentile à 95 % et part de même signe. 46
46 Statistiques descriptives et quantiles des PD. 47
47 PD moyenne et taux de défaut observé par décile de PD (test). 48
48 Hyperparamètres retenus et AUC de validation croisée. 50
49 Comparaison sur le test (1 966 prêts) : discrimination, qualité probabiliste et niveau moyen des PD. 50
50 Écart d'AUC avec la régression logistique : estimation, intervalle de confiance bootstrap à 95 % (1 000 tirages) et part des tirages où l'écart est négatif. 50
51 Importance des variables XGBoost (gain). 53
52 Comparaison qualitative des deux modèles. 54

Table des figures

1 Effectifs de la variable cible. 5
2 Taux de défaut par modalité des variables qualitatives (libellés harmonisés). Pointillés : taux global. 6
3 Part de la modalité dominante (en orange : au-dessus du seuil de 95 %). 7
4 Taux de valeurs manquantes par variable et nature du manquant (pointillés : seuil de 10 %). 8
5 Taux de défaut selon que la valeur est manquante ou renseignée (pointillés : taux global). 8
6 Taux de défaut des lignes signalées par chaque contrôle en anomalie (pointillés : taux global). 10
7 Credit Score avant et après correction (histogrammes empilés par statut). 10
8 Distributions sur l'apprentissage, avec les bornes des deux méthodes (montants en échelle logarithmique ; une borne hors de la plage observée n'est pas tracée). 14
9 Boîtes à moustaches : les points au-delà des moustaches (1,5 IQR) sont les outliers au sens IQR. 15
10 Part des observations signalées, par variable et par méthode. 16
11 Taux de défaut des observations signalées, par méthode. Pointillés : taux de l'apprentissage (23,5 %). 18
12 Distributions avant (contour) et après (barres) plafonnement, en échelle logarithmique. 20
13 Distributions des variables dérivées, avec les bornes des deux méthodes de détection (apprentissage). 24
14 Taux de défaut par quintile des variables dérivées (apprentissage). 24
15 Corrélations de Spearman entre variables dérivées et variables sources (apprentissage). 25

16 T de Tschuprow selon le nombre de quantiles, pour chaque variable (en orange : le découpage retenu). 28
17 IV des variables discrétisées. Pointillés : seuils de 0,02 (non prédictive en deçà) et de 0,10 (pouvoir moyen). 31
18 WoE par classe des huit variables de plus fort IV (orange : classe plus risquée que la moyenne). Étiquettes : taux de défaut et part de la classe. 32
19 Carte de chaleur des PSI entre échantillons bootstrap (échelle de 0 à 0,01, soit dix fois moins que le seuil de vigilance). 34
20 V de Cramér entre variables discrétisées. 37
21 Corrélations (Pearson) des variables codées en WoE ; en gras : $|r| > 0{,}4$. 38
22 Évolution du BIC au fil des étapes des trois procédures. 42
23 Contribution relative des variables du modèle final. 44
24 Distribution des coefficients sur les 100 échantillons bootstrap (losange : modèle initial). 46
25 Distribution des PD sur l'apprentissage et le test. 48
26 Calibration de la régression logistique par décile de PD sur le test (diagonale : calibration parfaite). 49
27 Courbes ROC sur le test. 51
28 PD des deux modèles pour les emprunteurs du test. 52
29 Calibration par décile de PD (test). 52
30 Distribution des PD des deux modèles sur le test. 52
31 Importance des variables XGBoost (part du gain total). 53